Autor:
Ronie Martínez

Limpieza de datos, Valores atípicos y Valores faltantes

Introducción

La limpieza de datos es un paso de vital importancia en cualquier proyecto de aprendizaje automático y ciencia de datos. En los datos tabulares, existen muchos análisis estadísticos diferentes y técnicas de visualización de datos que se pueden utilizar para explorar los datos a fin de identificar las operaciones de limpieza de datos que desee realizar. Existen algunas operaciones de limpieza básicas que probablemente se deberían realizar en todos los proyectos. Aunque a menudo se pasan por alto, son tan críticos que, si se omiten, los modelos pueden fallar o informar resultados de rendimiento demasiado optimistas. En esta lectura de profundización se presenta la limpieza de datos básica que siempre se debe realizar en el conjunto de datos.

Al modelar, es importante limpiar la muestra de datos para garantizar que las observaciones representen mejor el problema. A veces, un conjunto de datos puede contener valores extremos que están fuera del rango de lo esperado y diferentes a los demás datos. Estos se denominan valores atípicos (*outliers*) y, a menudo, el modelado de aprendizaje automático y la habilidad del modelo en general se pueden mejorar comprendiendo e incluso eliminando estos valores atípicos. Un valor atípico es una observación poco probable en un conjunto de datos y puede tener diversas causas.

Los datos también pueden perderse o faltar (*missing values*) debido a algunas razones, como observaciones que no fueron almacenadas o corrupción de datos. El manejo de este tipo de datos es importante ya que muchos algoritmos no soportan valores faltantes, por lo tanto, es necesario saber cómo identificarlos y marcarlos, además de criterios para remover o no estos registros.

Finalmente, hay ocasiones en las que no conviene remover registros, a pesar de que tengan datos faltantes. En estos casos existen métodos para la imputación o la sustitución de estos datos, y entre los métodos más comunes se encuentran la imputación estadística, utilizando KNN o iteraciones, y aunque no se profundicen estos métodos en esta materia, es importante conocer sobre su existencia y uso.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Contenido

Limpieza de datos básica

Identificar columnas que contienen valores únicos

Las columnas que tienen una única observación o valor, probablemente sean inútiles para el modelado. Estas columnas o predictores se denominan predictores de varianza cero, ya que si se midiera la varianza (valor promedio de la media), sería cero. Un valor único significa que cada fila de esa columna tiene el mismo valor. Las columnas que tienen un valor único para todas las filas no contienen ninguna información para modelar. Dependiendo de la elección de los algoritmos de modelado y preparación de datos, las variables con un solo valor también pueden provocar errores o resultados inesperados. Se pueden detectar filas que tienen esta propiedad utilizando la función unique() de NumPy, la cual informa el número de valores únicos en cada columna. Otro enfoque más sencillo es utilizar la función nunique() de Pandas que hace el trabajo duro de manera automática para las columnas del DataFrame.

Eliminar columnas que tengan valor único

Variables o columnas que tienen un valor único, podrían posiblemente ser removidos del conjunto de datos. Las columnas son relativamente sencillas de remover de un arreglo NumPy o un DataFrame de Pandas. Posiblemente la función más común para esta tarea es drop().

Considerar columnas que tengan muy pocos valores

Pueden existir casos de columnas que tengan muy pocos valores únicos. Esto podría tener sentido para variables ordinales o categóricas, pero no para variables numéricas. Como tal, puede resultar sorprendente tener solo 2, 4 o 9 valores numéricos únicos en una columna. Se refiere a estas columnas o predictores como predictores de varianza cercana a cero, ya que su varianza no es cero, sino un número muy pequeño cercano a cero. Estas columnas pueden contribuir o no a la habilidad de un modelo. No se puede asumir que sean inútiles para modelar.

Dependiendo de la elección de los algoritmos de modelado y preparación de datos, las variables con muy pocos valores numéricos también pueden provocar errores o resultados inesperados. Por ejemplo, pueden causar errores al usar

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

transformadas de potencia para la preparación de datos y al ajustar modelos lineales que asumen una distribución de probabilidad de datos sensible. Para ayudar a resaltar columnas de este tipo, se puede calcular la cantidad de valores únicos para cada variable como porcentaje del número total de filas en el conjunto de datos. Esto no significa necesariamente que estos datos deban eliminarse, pero si considerarlos con una mayor atención, por ejemplo: codificar como valores ordinales, codificar como valores categóricos, o comparar la habilidad del modelo con cada variable eliminada del conjunto de datos.

Remover columnas con varianza baja

Otro enfoque al problema de eliminar columnas con pocos valores únicos es considerar la varianza de la columna y utilizarla como filtro para identificar las columnas que se eliminarán del conjunto de datos. Una columna que tiene un valor único tiene una varianza de 0 y una columna que tiene muy pocos valores únicos puede tener una varianza pequeña. La clase VarianceThreshold de la librería Scikit-learn admite esto como un tipo de selección de características. Se puede crear una instancia de la clase y se puede especificar el argumento de umbral (por defecto es 0.0 para eliminar columnas con un solo valor). Luego se puede ajustar y aplicar a un conjunto de datos llamando a la función fit_transform() para crear una versión transformada del conjunto de datos donde las columnas que tienen una variación inferior al umbral se eliminan automáticamente.

Identificar filas que tengan datos duplicados

Las filas que tienen datos idénticos podrían ser inútiles para el proceso de modelado, incluso peligrosamente engañosas durante la evaluación del modelo. Desde la perspectiva de la evaluación del algoritmo, las filas duplicadas darán como resultado un rendimiento engañoso. Por ejemplo, si está utilizando una división de entrenamiento-prueba o una validación cruzada, entonces es posible que aparezcan una fila o filas duplicadas en los conjuntos de datos de entrenamiento y de prueba, y cualquier evaluación del modelo en estas filas será (o debería ser) correcto. Esto dará como resultado una estimación del rendimiento sesgada de manera optimista sobre datos no vistos.

La función duplicated() de Pandas informa si una fila determinada está duplicada o no. Todas las filas están marcadas como Falso para indicar que no es un duplicado o Verdadero para indicar que es un duplicado. Si hay duplicados, la primera aparición de la fila se marca como Falsa (de forma predeterminada).

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Eliminar filas que tengan datos duplicados

Las filas de datos duplicados probablemente deberían eliminarse del conjunto de datos antes de modelar. Si el conjunto de datos simplemente tiene filas duplicadas, no hay necesidad de preocuparse por preservar los datos; ya forma parte del conjunto de datos terminado y simplemente puede remover o eliminar estas filas de los datos limpios. Hay muchas maneras de lograr esto, aunque Pandas proporciona la función drop_duplicates() que logra exactamente esto.

Identificación y remoción de valores atípicos

Un valor atípico (*outlier*) es una observación que es diferente a las demás observaciones. Son elementos raros, distintos o que no encajan de alguna manera. Generalmente se definen como valores atípicos a las muestras que están excepcionalmente alejadas de la corriente principal de datos y que pueden tener distintas causas, por ejemplo:

- Error de medición o entrada.
- Corrupción de datos.
- Verdadera observación atípica.

No existe una forma precisa de definir e identificar valores atípicos en general debido a las características específicas de cada conjunto de datos. Incluso con una comprensión profunda de los datos, los valores atípicos pueden resultar difíciles de definir. Se debe tener mucho cuidado de no eliminar o cambiar valores apresuradamente, especialmente si el tamaño de la muestra es pequeño. Sin embargo, se pueden utilizar métodos estadísticos para identificar observaciones que parecen raras o improbables dados los datos disponibles.

Identificar valores atípicos y datos incorrectos en su conjunto de datos es probablemente una de las partes más difíciles de la limpieza de datos y lleva tiempo hacerlo bien. Incluso si se tiene un conocimiento profundo de las estadísticas y de cómo los valores atípicos pueden afectar los datos, siempre es un tema que se debe explorar con cautela. Esto no significa que los valores identificados sean valores atípicos y deban eliminarse. Un buen consejo es considerar graficar los valores atípicos identificados, tal vez en el contexto de valores no atípicos para ver si existe alguna relación o patrón sistemático con los

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

valores atípicos. Si los hay, tal vez no sean valores atípicos y puedan explicarse, o tal vez los valores atípicos mismos puedan identificarse de manera más sistemática.

Método de desviación estándar

Si se conoce que la distribución de valores en la muestra es gaussiana (o similar), se puede usar la desviación estándar de la muestra como límite para identificar valores atípicos. La distribución gaussiana tiene la propiedad de que la desviación estándar de la media se puede utilizar para resumir de manera confiable el porcentaje de valores en la muestra. Por ejemplo, dentro de una desviación estándar de la media se cubrirá el 68% de los datos. Entonces, si la media es 50 y la desviación estándar es 5, entonces todos los datos de la muestra entre 45 y 55 representarán aproximadamente el 68% de la muestra de datos. Se puede cubrir más muestras de datos si se amplía el rango de la siguiente manera:

1. Desviación estándar de la media: 68%.
2. Desviaciones estándar de la media: 95%.
3. Desviaciones estándar de la media: 99,7%.

Un valor que queda fuera de las 3 desviaciones estándar es parte de la distribución, pero es un evento poco probable o raro en aproximadamente 1 de cada 370 muestras. Tres desviaciones estándar de la media es un límite común en la práctica para identificar valores atípicos en una distribución gaussiana o similar. Para muestras de datos más pequeñas, quizás se pueda usar un valor de 2 desviaciones estándar (95%), y para muestras más grandes, quizás se pueda usar un valor de 4 desviaciones estándar (99,9%).

Se puede utilizar el mismo enfoque si se tienen datos multivariados, es decir, datos con múltiples variables, cada una con una distribución gaussiana diferente. Se puede imaginar límites en dos dimensiones que definirían una elipse para casos de dos variables. Las observaciones que quedan fuera de la elipse se considerarían valores atípicos. En tres dimensiones, esto sería un elipsoide, y así sucesivamente en dimensiones superiores.

Método de rango intercuartil

No todos los datos son normales o lo suficientemente normales como para tratarlos como si procedieran de una distribución gaussiana. Una buena estadística para resumir una muestra de datos de distribución no gaussiana es el rango intercuartil IQR. El IQR se calcula como la diferencia entre los

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

percentiles 75 y 25 de los datos y define el cuadro en un diagrama de caja y bigotes (*box and whisker plot*). Los percentiles se pueden calcular clasificando las observaciones y seleccionando valores en índices específicos. El percentil 50 es el valor medio, o el promedio de los dos valores medios para un número par de ejemplos. Para 10.000 muestras, el percentil 50 sería el promedio de los valores 5000 y 5001. Las técnicas de detección de valores atípicos basadas en estadísticas suponen que los puntos de datos normales aparecerían en regiones de alta probabilidad de un modelo estocástico, mientras que los valores atípicos ocurrirían en regiones de baja probabilidad de un modelo estocástico.

El IQR se puede utilizar para identificar valores atípicos definiendo límites en los valores de la muestra que son un factor *k* del IQR por debajo del percentil 25 o por encima del percentil 75. El valor común del factor *k* es el valor 1,5. Se puede utilizar un factor k de 3 o más para identificar valores que son valores atípicos extremos cuando se describen en el contexto de diagramas de caja y bigotes. En un diagrama de caja y bigotes, estos límites se dibujan como vallas en los bigotes (o las líneas) que se dibujan desde la caja. Los valores que quedan fuera de estos valores se dibujan como puntos. Para calcular los percentiles de un conjunto de datos se puede usar la función percentile() de NumPy que toma el conjunto de datos y la especificación del percentil deseado. Luego, el IQR se puede calcular como la diferencia entre los percentiles 75 y 25.

Detección automática

Un enfoque simple para identificar valores atípicos es ubicar aquellos ejemplos que están lejos de otros ejemplos en el espacio de características multidimensional. Esto puede funcionar bien para espacios de características con baja dimensionalidad (pocas características), aunque puede volverse menos confiable a medida que aumenta el número de características, lo que se conoce como la maldición de la dimensionalidad. El factor de valores atípicos locales LOF, es una técnica que intenta aprovechar la idea de los vecinos más cercanos para la detección de valores atípicos. A cada ejemplo se le asigna una puntuación de qué tan aislado o probable es que sean valores atípicos en función del tamaño de su vecindario local. Es más probable que los ejemplos con la puntuación más alta sean valores atípicos. La librería Scikit-learn proporciona una implementación de este enfoque en la clase LocalOutlierFactor. Otro de los algoritmos también ampliamente usados es el IsolationForest.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Valores faltantes

A la mayoría de los datos les faltan valores y la probabilidad de que falten valores aumenta con el tamaño del conjunto de datos. Los datos faltantes no son raros en conjuntos de datos reales. Inclusive, dependiendo la notación sobre el conjunto de datos, un valor igual a 0 o -1 puede no tener sentido e indicar un valor inválido o faltante.

En Python, específicamente Pandas, NumPy y Scikit-Learn, se marcan los valores faltantes como NaN. Los valores con un valor NaN se ignoran en operaciones como suma, recuento, etc. Se pueden marcar valores como NaN fácilmente con Pandas usando la función replace() en un subconjunto de las columnas que nos interesan. Después de haber marcado los valores perdidos, se puede usar la función isnull() para marcar todos los valores NaN en el conjunto de datos como True y obtener un recuento de los valores faltantes para cada columna.

Los valores faltantes son ocurrencias comunes en los datos. Desafortunadamente, la mayoría de las técnicas de modelado predictivo no pueden manejar ningún valor faltante (por ejemplo, LDA *Linear Discriminant Analysis*, SVM *Support Vector Machines* o NN *Neural Networks*). Por lo tanto, este problema debe abordarse antes del modelado.

Existen opciones para remover las filas con valores faltantes, por ejemplo utilizando el método dropna() se pueden remover tanto filas como columnas. Hay que tomar en cuenta que realizar este proceso de remoción, dependiendo la cantidad de datos removidos, puede dar resultados contraproducentes. En lugar de eso se pueden considerar métodos para imputar estos valores faltantes. Existen métodos para imputación estadística, imputación utilizando KNN e imputación iterativa.

Conclusiones

La limpieza de datos se refiere a identificar y corregir errores en el conjunto de datos que pueden afectar negativamente a un modelo predictivo. La limpieza de datos se utiliza para referirse a todo tipo de tareas y actividades para detectar y reparar errores en los datos. Aunque es de vital importancia, la limpieza de datos no es emocionante ni requiere técnicas sofisticadas, solo un buen conocimiento del conjunto de datos. Hay muchos tipos de errores que

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

existen en un conjunto de datos, aunque algunos de los errores más simples incluyen columnas que no contienen mucha información y filas duplicadas.

Existen algunas operaciones de limpieza básicas que probablemente se deberían realizar en todos los proyectos. Aunque a menudo se pasan por alto, son tan críticos que, si se omiten, los modelos pueden fallar o informar resultados de rendimiento demasiado optimistas. Estas operaciones consisten en identificación y eliminación de columnas que tengan valores únicos (varianza 0) o pocos valores (varianza baja, cercana a 0), y filas que contengan observaciones duplicadas.

Las anomalías o valores atípicos pueden identificarse mediante métodos estadísticos y dependen de la estructura de los datos de cada conjunto de datos específico. Entre los métodos más comunes para esta tarea están el de desviación estándar, el de rango intercuartil y métodos automáticos como LocalOutlierFactor o IsolationForest.

Los valores faltantes (*missing values*) son ocurrencias comunes en los datos, y desafortunadamente, la mayoría de las técnicas de modelado predictivo, incluyendo las más populares (LDA *Linear Discriminant Analysis*, SVM *Support Vector Machines* o NN *Neural Networks*), no pueden manejar ningún valor faltante. Por lo tanto, este problema debe abordarse antes del modelado. Existen técnicas para imputación o reemplazo de datos faltantes, que, aunque exceden el alcance de esta materia, es importante que se conozca sobre su existencia.

Referencias

Brownlee, J. (2020). *Data Preparation for Machine Learning Data Cleaning, Feature Selection, and Data Transforms in Python*. Machine Learning Mastery.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

+34 691 225 633
Rev. Febrero 2024

Autor:
Ronie Martínez

Preparación de datos sin fuga de datos

Introducción

La preparación de datos es el proceso de transformar datos sin procesar en una forma que sea apropiada para el modelado. Un enfoque ingenuo para preparar datos aplica la transformación en todo el conjunto de datos antes de evaluar el rendimiento del modelo. Esto da como resultado un problema conocido como fuga de datos (*data leakage*), donde el conocimiento del conjunto de pruebas (reservado) se filtra al conjunto de datos utilizado para entrenar al modelo. Esto puede dar como resultado una estimación incorrecta del rendimiento del modelo al realizar predicciones sobre datos nuevos. Se requiere una aplicación cuidadosa de las técnicas de preparación de datos para evitar la fuga de datos, y esto varía según el esquema de evaluación del modelo utilizado, como divisiones de prueba-entrenamiento (*test-train*) o validación cruzada (*k-fold cross-validation*). En esta lectura de profundización se abordará: cómo evitar la fuga de datos durante la preparación de datos al evaluar modelos de aprendizaje automático, cómo la aplicación ingenua (*naive*) de métodos de preparación de datos a todo el conjunto de datos da como resultado una fuga de datos que provoca estimaciones incorrectas del rendimiento del modelo, cómo la preparación de datos debe realizarse únicamente en el conjunto de entrenamiento para evitar la fuga de datos, y cómo implementar la preparación de datos sin fuga de datos para divisiones de *test-train* y *k-fold cross-validation* en Python.

Contenido

Problema con la preparación de datos ingenua

Un enfoque común para la preparación de datos es aplicar primero una o más transformaciones a todo el conjunto de datos. Posteriormente, el conjunto de datos se divide en conjuntos de entrenamiento y prueba o se utiliza una validación cruzada para probar y evaluar un modelo de aprendizaje automático.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Aunque este es un enfoque común, en la mayoría de los casos es peligrosamente incorrecto. El problema de aplicar técnicas de preparación de datos antes de dividirlos para la evaluación del modelo es que puede provocar una fuga de datos y, a su vez, probablemente dará como resultado una estimación incorrecta del desempeño de un modelo en el problema. La fuga de datos se refiere a un problema en el que la información sobre el conjunto de datos reservado, como un conjunto de datos de prueba o validación, se pone a disposición del modelo en el conjunto de datos de entrenamiento. Esta fuga suele ser pequeña y sutil, pero puede tener un efecto marcado en el rendimiento.

La fuga de datos se da al aplicar técnicas de preparación de datos a todo el conjunto de datos. Este no es un tipo directo de fuga de datos, en el que entrenaríamos el modelo en el conjunto de datos de prueba, en cambio, es un tipo indirecto de fuga de datos, en el que parte del conocimiento sobre el conjunto de datos de prueba, capturado en estadísticas resumidas, está disponible para el modelo durante el entrenamiento. Esto puede hacer que sea más difícil detectar un tipo de fuga de datos, especialmente para los principiantes. Otro aspecto del remuestreo está relacionado con el concepto de fuga de información, que es donde los datos del conjunto de pruebas se utilizan (directa o indirectamente) durante el proceso de entrenamiento. Esto puede conducir a resultados demasiado optimistas que no se replican en puntos de datos futuros y pueden ocurrir de manera sutil.

Por ejemplo, se puede considerar el caso en el que se quiera normalizar los datos, es decir, escalar las variables de entrada al rango 0-1. Cuando se normalizan las variables de entrada, esto requiere que primero calculemos los valores mínimo y máximo para cada variable antes de usar estos valores para escalar las variables. Después, el conjunto de datos se divide en conjuntos de datos de entrenamiento y de prueba, pero los ejemplos del conjunto de datos de entrenamiento saben algo sobre el conjunto de datos de prueba; han sido escalados según los valores mínimo y máximo globales, por lo que saben más sobre la distribución global de la variable de lo que deberían.

Se obtiene el mismo tipo de filtración con casi todas las técnicas de preparación de datos; por ejemplo, la estandarización estima los valores de media y desviación estándar del dominio para escalar las variables. Incluso los modelos que imputan valores faltantes utilizando un modelo o estadísticas resumidas aprovecharán el conjunto de datos completo para completar los valores en el conjunto de datos de entrenamiento. La solución es sencilla: la preparación de datos debe ajustarse únicamente al conjunto de datos de entrenamiento. Es decir, cualquier coeficiente o modelo preparado para el proceso de preparación

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

de datos solo se deben utilizar filas de datos en el conjunto de datos de entrenamiento. Una vez se hayan entrenado los algoritmos o modelos, entonces ahí se puede aplicar la preparación de datos al conjunto de datos de prueba, eso incluye transformación de datos, selección de características, reducción de dimensionalidad, ingeniería de características, etc.

Preparación de datos con conjuntos de entrenamiento y pruebas

Para esta sección, se evalúa un modelo de regresión logística utilizando conjuntos de entrenamiento y pruebas sobre un dataset de clasificación binaria, cuyas variables de entrada han sido normalizadas. Para crear este conjunto de datos se utiliza la función make_classification() de sklearn, con los siguientes parámetros: 1000 filas de datos y 20 características de entrada numéricas.

El acercamiento ingenuo (incorrecto) consiste en aplicar primero el método de preparación de datos, y luego dividir los datos para posteriormente evaluar el modelo. Se pueden normalizar las variables de entrada utilizando la clase MinMaxScaler para escalar los datos en el rango 0-1, después se utiliza la función fit_transform() para aplicar esto a todo el conjunto de datos. El resultado es una versión normalizada de las variables de entrada (cada columna separada en función de sus propios máximos y mínimos). Luego, se divide el conjunto de datos en los conjuntos de entrenamiento y pruebas (67%-33%), utilizando la función train_test_split(). Posteriormente se define el modelo/algoritmo mediante la clase LogisticRegression con su configuración por defecto y se lo entrena con el conjunto de entrenamiento. Para la evaluación del modelo se utiliza el método predict() sobre el conjunto de pruebas y se comparan estos valores calculados con los valores reales, de esta manera se obtiene el puntaje de exactitud (accuracy score). En este ejemplo se obtiene un porcentaje de exactitud de 84.848%.

Ahora, el acercamiento correcto para aplicar este proceso es, primero dividir el conjunto de datos en entrenamiento y pruebas, para luego realizar el proceso de normalización, entrenamiento y evaluación. De esta manera, al calcular los mínimos y máximos del conjunto de entrenamiento en lugar de todo el conjunto de datos, se evita esta mencionada fuga de datos. Para este ejemplo, utilizando correctamente el proceso de preparación de datos, se obtiene un porcentaje de exactitud de 85.455%.

Ambos scripts se encuentran disponibles para revisión en la sección Anexos.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Preparación de datos para validación cruzada k-fold

Para esta sección, se evalúa el mismo modelo de regresión logística utilizando validación cruzada *k-fold* sobre el mismo *dataset* de clasificación binaria. Este tipo de validación consiste en dividir el conjunto de datos en *k* subgrupos, y se entrena el modelo con todos los subgrupos, excepto uno (utilizado como conjunto de pruebas); este proceso se repite *k* veces, hasta que cada subgrupo haya sido considerado como conjunto de pruebas. Generalmente, este acercamiento se puede considerar como más confiable (en comparación con la división *train-test*) para evaluar el desempeño del modelo, desde luego, es computacionalmente más costoso.

El acercamiento ingenuo consiste en aplicar la transformación de datos primero y luego utilizar el procedimiento de validación cruzada. Para este ejemplo se utiliza *k* igual a 10, utilizando los métodos RepeatedStratifiedKFold y cross_val_score(), obteniendo un porcentaje de exactitud promedio de 85.3% con desviación estándar 3.607%.

De igual manera, el acercamiento correcto para aplicar este proceso de validación cruzada es ligeramente más retador. Para esto se puede utilizar un modelado pipeline, que define una secuencia de los pasos de preparación de datos para aplicarlo de manera correcta. Para este ejemplo, utilizando correctamente el proceso de preparación de datos con validación cruzada, se obtiene un porcentaje de exactitud promedio de 85.433% con desviación estándar 3.471%.

Ambos scripts también se encuentran disponibles para revisión en la sección Anexos.

Conclusiones

La fuga significa que revela información al modelo que le otorga una ventaja poco realista para hacer mejores predicciones. Esto podría suceder cuando se filtran datos de prueba al conjunto de entrenamiento o cuando se filtran datos del futuro al pasado. Cada vez que a un modelo se le proporciona información a la que no debería tener acceso cuando realiza predicciones en tiempo real en producción, se produce una fuga.

Para evitar esta fuga de datos, es importante primero dividir/identificar los conjuntos de entrenamiento y pruebas, para posteriormente aplicar la

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

preparación de datos solamente sobre el conjunto de entrenamiento, evitando así extraer información subyacente del conjunto de pruebas, el cual solo debe ser utilizado para la evaluación de los modelos. Dependiendo del *dataset* al que se apliquen estos procesos es posible que la diferencia entre los enfoques ingenuos (incorrecto) y correcto refleje un resultado apenas diferenciable, sin embargo, no por esto se puede obviar este paso importante para evitar la fuga de datos.

Los resultados específicos de los scripts contenidos en los anexos pueden variar dada la naturaleza estocástica del algoritmo de aprendizaje, el procedimiento de evaluación o las diferencias en cuanto a precisión numérica. Para comparar los posibles resultados diferentes, se recomienda ejecutar el script varias veces y comparar estos desempeños a manera de promedio.

Referencias

Brownlee, J. (2020). *Data Preparation for Machine Learning Data Cleaning, Feature Selection, and Data Transforms in Python*. Machine Learning Mastery.

Anexos

Preparación de datos con conjuntos de entrenamiento y pruebas

Naive (incorrecto)

```
# naive approach to normalizing the data before splitting the data and evaluating the model
from sklearn.datasets import make_classification
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import MinMaxScaler
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score
# define dataset
```

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

```
X, y = make_classification(n_samples=1000, n_features=20, n_informative=15, n_redundant=5, random_state=7)

# standardize the dataset

scaler = MinMaxScaler()

X = scaler.fit_transform(X)

# split into train and test sets

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.33, random_state=1)

# fit the model

model = LogisticRegression()

model.fit(X_train, y_train)

# evaluate the model

yhat = model.predict(X_test)

# evaluate predictions

accuracy = accuracy_score(y_test, yhat)

print('Accuracy: %.3f' % (accuracy*100))
```

Correcto

```
# correct approach for normalizing the data after the data is split before the model is evaluated

from sklearn.datasets import make_classification

from sklearn.model_selection import train_test_split

from sklearn.preprocessing import MinMaxScaler

from sklearn.linear_model import LogisticRegression

from sklearn.metrics import accuracy_score

# define dataset
```

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

```
X, y = make_classification(n_samples=1000, n_features=20, n_informative=15, n_redundant=5, random_state=7)

# split into train and test sets

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.33, random_state=1)

# define the scaler

scaler = MinMaxScaler()

# fit on the training dataset

scaler.fit(X_train)

# scale the training dataset

X_train = scaler.transform(X_train)

# scale the test dataset

X_test = scaler.transform(X_test)

# fit the model

model = LogisticRegression()

model.fit(X_train, y_train)

# evaluate the model

yhat = model.predict(X_test)

# evaluate predictions

accuracy = accuracy_score(y_test, yhat)

print('Accuracy: %.3f' % (accuracy*100))
```

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Preparación de datos con validación cruzada

Naive (incorrecto)

```
# naive data preparation for model evaluation with k-fold cross-validation
from numpy import mean
from numpy import std
from sklearn.datasets import make_classification
from sklearn.model_selection import cross_val_score
from sklearn.model_selection import RepeatedStratifiedKFold
from sklearn.preprocessing import MinMaxScaler
from sklearn.linear_model import LogisticRegression
# define dataset
X, y = make_classification(n_samples=1000, n_features=20, n_informative=15,
n_redundant=5, random_state=7)
# standardize the dataset
scaler = MinMaxScaler()
X = scaler.fit_transform(X)
# define the model
model = LogisticRegression()
# define the evaluation procedure
cv = RepeatedStratifiedKFold(n_splits=10, n_repeats=3, random_state=1)
# evaluate the model using cross-validation
scores = cross_val_score(model, X, y, scoring='accuracy', cv=cv, n_jobs=-1)
# report performance
print('Accuracy: %.3f (%.3f)' % (mean(scores)*100, std(scores)*100))
```

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Correcto

```
# correct data preparation for model evaluation with k-fold cross-validation
from numpy import mean
from numpy import std
from sklearn.datasets import make_classification
from sklearn.model_selection import cross_val_score
from sklearn.model_selection import RepeatedStratifiedKFold
from sklearn.preprocessing import MinMaxScaler
from sklearn.linear_model import LogisticRegression
from sklearn.pipeline import Pipeline
# define dataset
X, y = make_classification(n_samples=1000, n_features=20, n_informative=15,
n_redundant=5, random_state=7)
# define the pipeline
steps = list()
steps.append(('scaler', MinMaxScaler()))
steps.append(('model', LogisticRegression()))
pipeline = Pipeline(steps=steps)
# define the evaluation procedure
cv = RepeatedStratifiedKFold(n_splits=10, n_repeats=3, random_state=1)
# evaluate the model using cross-validation
scores = cross_val_score(pipeline, X, y, scoring='accuracy', cv=cv, n_jobs=-1)
# report performance
print('Accuracy: %.3f (%.3f)' % (mean(scores)*100, std(scores)*100))
```

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

+34 691 225 633
Rev. Febrero 2024

Autor:
Ronie Martínez

Preparación y procesamiento de datos

Introducción

La preparación de datos puede ser la parte más importante de un proyecto de aprendizaje automático o ciencia de datos. Es la parte que lleva más tiempo, aunque parece ser el tema menos discutido. La preparación de datos, a veces denominada preprocesamiento de datos, es el acto de transformar datos sin procesar en una forma que sea apropiada para el modelado. Los algoritmos de aprendizaje automático requieren que los datos de entrada sean números y la mayoría de las implementaciones de algoritmos mantienen esta expectativa. Como tal, si los datos contienen tipos de datos y valores que no son números, como etiquetas, se deberán convertir los datos en números. Además, los algoritmos específicos de aprendizaje automático tienen expectativas con respecto a los tipos de datos, la escala, la distribución de probabilidad y las relaciones entre las variables de entrada, y es posible que sea necesario cambiar los datos para cumplir con estas expectativas.

Palabras clave

Procesamiento de datos, limpieza, manipulación, selección de características.

Reto

Los modelos de aprendizaje automático para ciencias de datos se entrenan con valores numéricos, es decir, los datos crudos obtenidos en etapas de recolección de datos necesitan ser preparados y manipulados para cumplir con esta especificación. En este tema se presentan las explicaciones y justificaciones de estos procesos, además de las técnicas utilizadas más comunes.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Desarrollo

Preparación de datos en un proyecto

El principal desafío de la preparación de datos radica en que cada conjunto de datos es único y diferente (proyectos específicos). Los conjuntos de datos difieren en el número de variables (decenas, centenas, miles o más), los tipos de variables (numéricas, nominales, ordinales, booleanas), la escala de las variables, la variación (*drift*) de los valores a lo largo del tiempo, etc. Como tal, esto hace que discutir la preparación de datos sea un desafío. Se utilizan estudios de casos específicos o se centra la atención en los métodos generales que se pueden utilizar en los proyectos. Típicamente, los datos en crudo (*raw data*) no se puede utilizar directamente, debido a las siguientes razones:

- Algoritmos de aprendizaje automático ML (*machine learning*) requieren que los datos sean numéricos.
- Algunos algoritmos de ML imponen ciertos requisitos sobre los datos.
- Es posible que sea necesario corregir el ruido estadístico y los errores en los datos.
- Se pueden extraer relaciones no lineales complejas de los datos.

Los datos deben procesarse previamente antes de usarse para probar y evaluar un modelo de ML. Este paso, en un proyecto de modelado predictivo, se conoce como preparación de datos, aunque tiene muchos otros nombres, como manipulación de datos, limpieza de datos, preprocesamiento de datos e ingeniería de características (*feature engineering*). Algunos de estos nombres pueden encajar mejor como subtareas para el proceso más amplio de preparación de datos. Se puede definir la preparación de datos como la transformación de datos sin procesar a una forma que sea más adecuada para el modelado. De esta manera, las tareas estándar o más comunes que se pueden usar o explorar durante el paso de preparación de los datos son las siguientes:

- **Limpieza de Datos (*data cleaning*):** Identificar y corregir errores en los datos.
- **Selección de características (*feature selection*):** identificar aquellas variables de entrada que son más relevantes para la tarea.
- **Transformaciones de datos (*data transforms*):** cambiar la escala o distribución de variables.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

- **Ingeniería de características (*feature engineering*):** derivar u obtener nuevas variables a partir de los datos disponibles.
- **Reducción de dimensionalidad (*dimensionality reduction*):** Creación de proyecciones compactas de los datos.

Cada una de estas tareas es un campo completo de estudio con algoritmos especializados, por lo que en esta semana se tratará de cubrir estos temas de manera resumida y enfocándose en los puntos más importantes. La filosofía más amplia de la preparación de datos es descubrir cómo exponer mejor la estructura subyacente del problema a los algoritmos de aprendizaje. No se conoce la estructura subyacente del problema; si se la conociera, no se necesitaría un algoritmo de aprendizaje para descubrirlo y aprender a hacer predicciones hábiles. Por lo tanto, exponer la estructura subyacente desconocida del problema es un proceso de descubrimiento, además de descubrir los algoritmos de aprendizaje con mejor rendimiento para el proyecto.

A primera vista, la selección de las técnicas para la preparación de datos es un tema desafiante, pero si se mira el paso de preparación de datos en el contexto de todo el proyecto, se vuelve más sencillo. Los pasos de un proyecto de modelado predictivo antes y después del paso de preparación de datos informan la preparación de datos que puede ser necesaria. El paso previo a la preparación de los datos implica definir el problema. Como parte de la definición del problema, esto puede implicar muchas subtareas, tales como:

- Recopilar datos del dominio del problema.
- Discutir el proyecto con expertos en la materia.
- Seleccionar aquellas variables que se utilizarán como entradas y salidas para un modelo predictivo.
- Revisar los datos que se han recopilado.
- Resumir los datos recopilados utilizando métodos estadísticos.
- Visualizar los datos recopilados mediante gráficos y diagramas.

La información conocida sobre los datos se puede utilizar para seleccionar y configurar métodos de preparación de datos. Por ejemplo, los gráficos de los datos pueden ayudar a identificar si una variable tiene valores atípicos. Esto puede ayudar en las operaciones de limpieza de datos. También puede proporcionar información sobre la distribución de probabilidad que subyace a los datos. Esto puede ayudar a determinar si serían apropiadas las

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

transformaciones de datos que cambian la distribución de probabilidad de una variable. Se pueden utilizar métodos estadísticos, como las estadísticas descriptivas, para determinar si podrían ser necesarias operaciones de escala. Las pruebas de hipótesis estadísticas se pueden utilizar para determinar si una variable coincide con una distribución de probabilidad determinada.

Se pueden utilizar gráficos por pares (*pairwise plot*) y estadísticas para determinar si las variables están relacionadas y, de ser así, en qué medida, proporcionando información sobre si una o más variables son redundantes o irrelevantes para la variable objetivo. Como tal, puede haber mucha interacción entre la definición del problema y la preparación de los datos. También puede haber una interacción entre el paso de preparación de datos y la evaluación de modelos. La evaluación del modelo puede implicar subtareas como:

- Seleccionar una métrica de rendimiento para evaluar la habilidad predictiva del modelo.
- Seleccionar un procedimiento de evaluación del modelo.
- Seleccionar algoritmos para evaluar.
- Ajustar los hiperparámetros del algoritmo.
- Combinar modelos predictivos en conjuntos (*ensembles*).

La información conocida sobre la elección de algoritmos y el descubrimiento de algoritmos de buen rendimiento también puede informar la selección y configuración de los métodos de preparación de datos. Por ejemplo, la elección de algoritmos puede imponer requisitos y expectativas sobre el tipo y la forma de las variables de entrada en los datos. Esto podría requerir que las variables tengan una distribución de probabilidad específica, la eliminación de variables de entrada correlacionadas y/o la eliminación de variables que no están fuertemente relacionadas con la variable objetivo. La elección de la métrica de desempeño también puede requerir una preparación cuidadosa de la variable objetivo para cumplir con las expectativas, como calificar modelos de regresión basados en el error de predicción usando una unidad de medida específica, lo que requiere la inversión de cualquier transformación de escala aplicada a esa variable para modelar. Estos y más ejemplos, resaltan que, si bien la preparación de datos es un paso importante en un proyecto de modelado predictivo, no es un paso independiente. Más bien, está fuertemente influenciado por las tareas realizadas antes y después de la preparación de los datos. Esto resalta la naturaleza altamente iterativa de cualquier proyecto de modelado predictivo.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Importancia de la preparación de datos

En un proyecto de modelado predictivo, los algoritmos de ML aprenden un mapeo de las variables de entrada, a una variable objetivo. La forma más común de proyecto de modelado predictivo implica los llamados datos estructurados o datos tabulares. Se trata de datos tal como se ven en una hoja de cálculo o una matriz, con filas de ejemplos y columnas de características para cada ejemplo. No se pueden adaptar y evaluar algoritmos de ML en datos sin procesar; en cambio, se tienen que transformar los datos para cumplir con los requisitos de los algoritmos.

En álgebra lineal, se puede referir a una tabla de datos como una matriz. La tabla se compone de filas y columnas. Una fila representa un ejemplo del dominio del problema y puede denominarse como: ejemplo, instancia, caso o muestra. Una columna representa las propiedades observadas en el ejemplo y puede denominarse variable, característica o atributo. En este aspecto, las columnas utilizadas para la entrada del modelo se denominan variables de entrada y la columna que contiene el objetivo que se va a predecir se denomina variable de salida. Las filas utilizadas para entrenar un modelo se denominan conjunto de datos de entrenamiento y las filas utilizadas para evaluar el modelo se denominan conjunto de datos de prueba.

Cuando se recopilen los datos, es posible que se tengan que manipular para que formen una tabla grande. Por ejemplo, si se tienen los datos en una base de datos relacional, es común representar entidades en tablas separadas en lo que se conoce como forma normal para minimizar la redundancia. Para crear una tabla grande con una fila por tema o entidad que desea modelar, es posible que deba revertir este proceso e introducir redundancia en los datos en un proceso denominado desnormalización. Si los datos están en una hoja de cálculo o base de datos, es una práctica estándar extraer y guardar los datos en formato CSV. Se trata de una representación estándar que es portátil, bien comprendida y lista para el proceso de modelado predictivo sin dependencias externas.

Aunque los datos estén representados en una tabla grande de filas y columnas, las variables de la tabla pueden tener diferentes tipos de datos. Algunas variables pueden ser numéricas, como números enteros, valores de punto flotante, rangos, tasas, porcentajes, etc. Otras variables pueden ser nombres, categorías o etiquetas representadas con caracteres o palabras, y algunas pueden ser binarias, representadas con 0 y 1 o Verdadero y Falso. El problema es que, en esencia, los algoritmos de ML operan con datos numéricos. Toman

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

números como entrada y predicen un número como salida. Todos los datos se ven como vectores y matrices, utilizando la terminología del álgebra lineal.

Como tal, los datos sin procesar deben cambiarse antes de entrenar, evaluar y utilizar modelos de ML. A veces, los cambios en los datos pueden gestionarse internamente mediante el algoritmo, pero, por lo general, esto debe ser manejado por el profesional antes del modelado.

Incluso si los datos sin procesar contienen solo números, es probable que se requiera cierta preparación de datos. Hay muchos algoritmos diferentes de para elegir para un proyecto de modelado predictivo determinado. No se puede saber qué algoritmo será el apropiado y mucho menos cuál será el más adecuado para la tarea. Por lo tanto, es una buena práctica evaluar sistemáticamente un conjunto de diferentes algoritmos candidatos y descubrir cuál funciona bien o mejor con los datos. El problema es que cada algoritmo tiene requisitos o expectativas específicos con respecto a los datos. De igual manera, incluso si se preparan los datos para cumplir con las expectativas de cada modelo, es posible que no se obtenga el mejor rendimiento. El desempeño de un algoritmo de ML es tan bueno como los datos utilizados en el entrenamiento.

Técnicas para la preparación de datos

Tareas comunes

Como ya se mencionó, se puede definir la preparación de datos como la transformación de datos sin procesar a una forma que sea más adecuada para el modelado. Sin embargo, hay pasos en un proyecto de modelado predictivo antes y después del paso de preparación de datos que son importantes e informan la preparación de datos que se va a realizar. Se puede saltar de un lado a otro entre los pasos de cualquier proyecto determinado, pero todos los proyectos tienen los mismos pasos generales; ellos son:

- **Paso 1:** Definir el problema.
- **Paso 2:** Preparar los datos.
- **Paso 3:** Evaluar modelos.
- **Paso 4:** Finalizar el modelo.

Existen tareas comunes o estándares que pueden usar o explorar durante el paso de preparación de datos en un proyecto. A medida que se trabaja en

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

múltiples proyectos de modelado predictivo, se ve y se requieren los mismos tipos de tareas de preparación de datos una y otra vez. Estas tareas incluyen:

- Limpieza de Datos.
- Selección de características.
- Transformaciones de datos.
- Ingeniería de características.
- Reducción de dimensionalidad.

Esto proporciona un marco de trabajo aproximado que se puede utilizar para pensar y navegar por diferentes algoritmos de preparación de datos que se pueden considerar en un proyecto determinado con datos estructurados o tabulares.

Limpieza de datos

La limpieza de datos implica solucionar problemas sistemáticos o errores en datos desordenados. La limpieza de datos más útil implica una profunda experiencia en el dominio y podría implicar identificar y abordar observaciones específicas que pueden ser incorrectas. Hay muchas razones por las que los datos pueden tener valores incorrectos, como estar mal escritos, dañados, duplicados, etc. La experiencia en el dominio puede permitir identificar observaciones obviamente erróneas, que sean diferentes de lo esperado (por ejemplo, la altura de una persona igual a 180 m). Una vez que se identifican las observaciones confusas, ruidosas, corruptas o erróneas, se pueden abordar. Esto podría implicar eliminar una fila o una columna. Alternativamente, podría implicar reemplazar las observaciones con nuevos valores. Como tal, existen operaciones generales de limpieza de datos que se pueden realizar, tales como:

- Usar estadísticas para definir datos normales e identificar valores atípicos.
- Identificar columnas que tienen el mismo valor o ninguna varianza y eliminarlas.
- Identificar filas duplicadas de datos y eliminarlas.
- Marcar valores vacíos como faltantes.
- Imputar o completar valores faltantes utilizando estadísticas o un modelo aprendido.

La limpieza de datos es una operación que normalmente se realiza primero, antes de otras operaciones de preparación de datos.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

ILUSTRACIÓN 1. RESUMEN DE LA LIMPIEZA DE DATOS

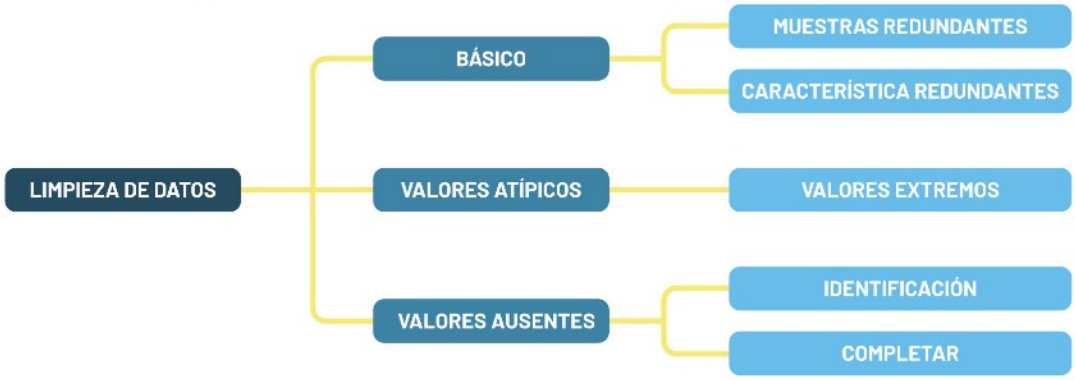

Selección de características

La selección de características se refiere a técnicas para seleccionar un subconjunto de características de entrada que son más relevantes para la variable objetivo que se predice. Esto es importante ya que las variables de entrada irrelevantes y redundantes pueden distraer o engañar a los algoritmos de aprendizaje, lo que posiblemente resulte en un menor rendimiento predictivo. Además, es deseable desarrollar modelos utilizando únicamente los datos necesarios para hacer una predicción, es decir, favorecer el modelo más simple posible con buen rendimiento. Las técnicas de selección de características generalmente pueden agruparse en aquellas que utilizan la variable objetivo (supervisadas) y aquellas que no (no supervisadas). Además, las técnicas supervisadas se pueden dividir en modelos que seleccionan automáticamente características como parte del ajuste del modelo (intrínsecas), aquellas que eligen explícitamente características que dan como resultado el modelo de mejor rendimiento (*wrapper*) y aquellas que califican cada característica de entrada y permiten seleccionar un subconjunto (filtro).

Los métodos estadísticos, como la correlación, son populares para calificar las características de entrada. Las características se pueden clasificar según sus puntuaciones y utilizar un subconjunto con las puntuaciones más altas como entrada para un modelo. La elección de la medida estadística depende de los tipos de datos de las variables de entrada. Además, existen diferentes casos de uso de selección de características comunes que se pueden encontrar en un proyecto de modelado predictivo como:

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

- Entradas categóricas para una variable objetivo de clasificación.
- Entradas numéricas para una variable objetivo de clasificación.
- Entradas numéricas para una variable objetivo de regresión.

Como alternativa, se puede utilizar un método contenedor, como el popular método de eliminación de características recursivas (RFE *Recursive Feature Elimination*), que es independiente del tipo de variable de entrada.

ILUSTRACIÓN 2. RESUMEN DE LA SELECCIÓN DE CARACTERÍSTICAS

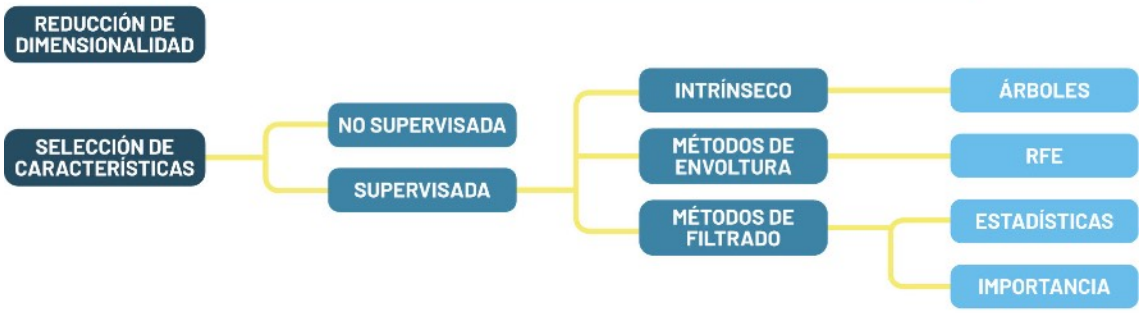

Transformación de datos

Las transformaciones de datos se utilizan para cambiar el tipo o la distribución de las variables de datos. Se trata de un amplio abanico de técnicas diferentes y pueden aplicarse con la misma facilidad a variables de entrada y de salida. Los datos pueden tener varios tipos:

- **Tipo de datos numéricos:** valores numéricos.
  - **Entero:** Enteros sin parte fraccionaria.
  - **Flotante:** Valores con decimales.
- **Tipo de datos categóricos:** valores de etiqueta.
  - **Ordinal:** Etiquetas con un orden de clasificación.
  - **Nominal:** Etiquetas sin orden de clasificación.
  - **Booleano:** Valores Verdadero y Falso.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Es posible que se desee convertir una variable numérica en una variable ordinal en un proceso llamado discretización. Alternativamente, se puede codificar una variable categórica como números enteros o variables booleanas, lo que se requiere en la mayoría de las tareas de clasificación. Una consideración importante con las transformaciones de datos es que las operaciones generalmente se realizan por separado para cada variable.

ILUSTRACIÓN 3. RESUMEN DE TRANSFORMACIÓN DE DATOS

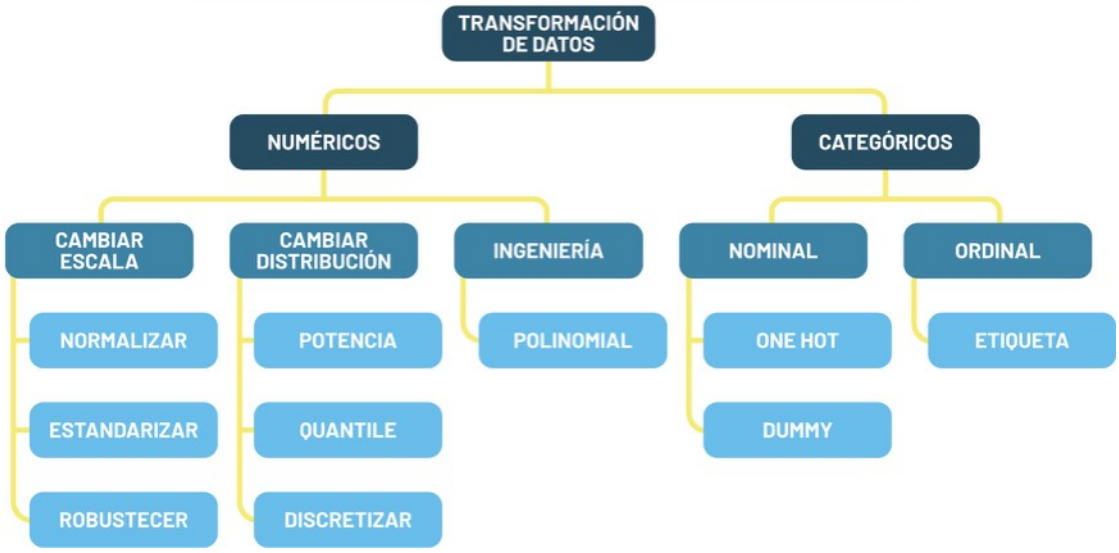

Ingeniería de características

La ingeniería de características se refiere al proceso de creación de nuevas variables de entrada a partir de los datos disponibles. La ingeniería de nuevas funciones es muy específica de sus datos y tipos de datos. Como tal, a menudo requiere la colaboración de un experto en la materia para ayudar a identificar nuevas características que podrían construirse a partir de los datos. Esta especialización hace que sea un tema difícil de generalizar a métodos generales. Sin embargo, existen algunas técnicas que se pueden reutilizar, como, por ejemplo:

- Agregar una variable booleana para algún estado (bandera).
- Agregar un grupo o una estadística de resumen global, como una media.
- Agregar nuevas variables para cada componente de una variable compuesta, como una fecha y hora.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Reducción de dimensionalidad

El número de características de entrada para un conjunto de datos puede considerarse la dimensionalidad de los datos. Por ejemplo, dos variables de entrada juntas pueden definir un área bidimensional donde cada fila de datos define un punto en ese espacio. Esta idea se puede ampliar a cualquier número de variables de entrada para crear grandes hipervolúmenes multidimensionales. El problema es que cuantas más dimensiones tenga este espacio (por ejemplo, más variables de entrada), más probable será que el conjunto de datos represente una muestra muy escasa y probablemente no representativa de ese espacio. Esto se conoce como la maldición de la dimensionalidad.

Esto motiva la selección de características, aunque una alternativa a la selección de características es crear una proyección de los datos en un espacio de dimensiones inferiores que aún conserve las propiedades más importantes de los datos originales. Esto se conoce generalmente como reducción de dimensionalidad y proporciona una alternativa a la selección de características. A diferencia de la selección de características, las variables de los datos proyectados no están directamente relacionadas con las variables de entrada originales, lo que dificulta la interpretación de la proyección.

ILUSTRACIÓN 4. RESUMEN DE REDUCCIÓN DE DIMENSIONALIDAD

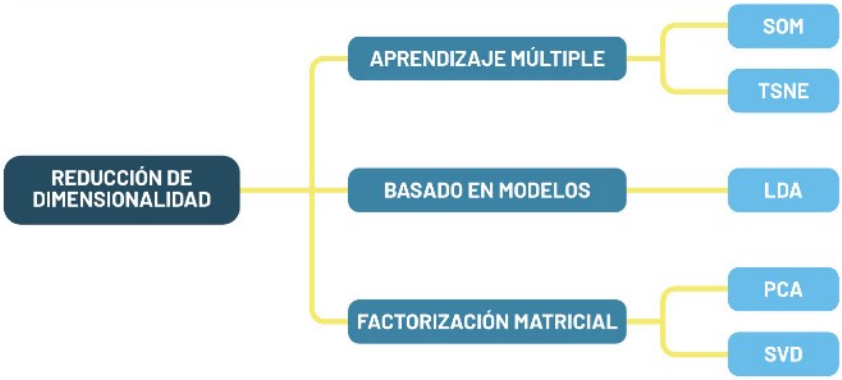

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Conclusiones

La preparación de datos puede ser considerada una parte vital en proyectos de aprendizaje automático o ciencia de datos. Es un proceso complejo que puede llevar bastante tiempo, aunque muchas veces es el que menos se considera y discute. La preparación de datos también se la conoce como manipulación de datos, limpieza de datos, preprocesamiento de datos e ingeniería de características (*feature engineering*). Algunos de estos nombres pueden encajar mejor como subtareas para el proceso más amplio de preparación de datos. En general, es el acto de transformar datos sin procesar en una forma que sea apropiada para el modelado. Los algoritmos de aprendizaje automático requieren que los datos de entrada sean numéricos y la mayoría de las implementaciones de algoritmos mantienen esta expectativa.

Se descubrió cómo considerar la preparación de datos como un paso en un proyecto más amplio de aprendizaje automático de modelado predictivo y/o ciencia de datos. Cada proyecto de modelado predictivo con aprendizaje automático es diferente, pero se realizan pasos comunes en cada proyecto. La preparación de datos implica exponer mejor la estructura subyacente desconocida del problema a los algoritmos de aprendizaje. Los pasos antes y después de la preparación de datos en un proyecto pueden informar qué métodos de preparación de datos aplicar, o al menos explorar.

Los datos estructurados en el aprendizaje automático constan, generalmente, de filas y columnas. La preparación de datos es un paso obligatorio en cada proyecto de aprendizaje automático. La rutina de los algoritmos de aprendizaje automático significa que la mayor parte del esfuerzo de cada proyecto se dedica a la preparación de datos.

La preparación de datos es un paso importante en un proyecto de modelado predictivo, no es un paso independiente, más bien está fuertemente influenciado por las tareas realizadas antes y después de la preparación de los datos. Esto resalta la naturaleza altamente iterativa de cualquier proyecto de modelado predictivo.

Técnicas como la limpieza de datos pueden ayudar a identificar y corregir errores en los datos, como valores perdidos. La transformación de los datos ayuda a cambiar la escala, el tipo, la distribución de probabilidad en el conjunto de datos. Técnicas como la selección de características y la reducción de dimensionalidad pueden reducir el número de variables de entrada.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Se presentaron las tareas más comunes de preparación de datos realizadas en una tarea de aprendizaje automático de modelado predictivo. Las técnicas, como la limpieza de datos, pueden identificar y corregir errores en datos como valores faltantes. Las transformaciones de datos pueden cambiar la escala, el tipo y la distribución de probabilidad de las variables en el conjunto de datos. Técnicas como la selección de características y la reducción de dimensionalidad pueden reducir la cantidad de variables de entrada.

El objetivo de la ingeniería de características es agregar un contexto más amplio a una sola observación o descomponer una variable compleja, ambos en un esfuerzo por proporcionar una perspectiva más sencilla de los datos de entrada. Algunos autores consideran la ingeniería de características como un tipo de transformación de datos, aunque sería igualmente razonable pensar en las transformaciones de datos como un tipo de ingeniería de características.

Referencias

Brownlee, J. (2020). *Data Preparation for Machine Learning Data Cleaning, Feature Selection, and Data Transforms in Python*. Machine Learning Mastery.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

PREPARACIÓN Y PROCESAMIENTO DATOS

1 LIMPIEZA DE DATOS

IDENTIFICAR Y CORREGIR ERRORES EN LOS DATOS.

- LIMPIEZA DE DATOS
  - BÁSICO
    - MUESTRAS REDUNDANTES
    - CARACTERÍSTICA REDUNDANTES
  - VALORES ATÍPICOS
    - VALORES EXTREMOS
  - VALORES AUSENTES
    - IDENTIFICACIÓN
    - COMPLETAR

2 SELECCIÓN DE CARACTERÍSTICAS

IDENTIFICAR AQUELLAS VARIABLES DE ENTRADA QUE SON MÁS RELEVANTES.

- REDUCCIÓN DE DIMENSIONALIDAD
- SELECCIÓN DE CARACTERÍSTICAS
  - NO SUPERVISADA
  - SUPERVISADA
    - INTRÍNSECO
      - ÁRBOLES
    - MÉTODOS DE ENVOLTURA
      - RFE
    - MÉTODOS DE FILTRADO
      - ESTADÍSTICAS
      - IMPORTANCIA

3 TRANSFORMACIÓN DE DATOS

CAMBIAR LA ESCALA O DISTRIBUCIÓN DE VARIABLES.

- TRANSFORMACIÓN DE DATOS
  - NUMÉRICOS
    - CAMBIAR ESCALA
      - NORMALIZAR
      - ESTANDARIZAR
      - ROBUSTECER
    - CAMBIAR DISTRIBUCIÓN
      - POTENCIA
      - QUANTILE
      - DISCRETIZAR
    - INGENIERÍA
      - POLINOMIAL
  - CATEGÓRICOS
    - NOMINAL
      - ONE HOT
      - DUMMY
    - ORDINAL
      - ETIQUETA

4 INGENIERÍA DE CARACTERÍSTICAS

DERIVAR U OBTENER NUEVAS VARIABLES A PARTIR DE LOS DATOS DISPONIBLES.

5 REDUCCIÓN DE DIMENSIONALIDAD

CREACIÓN DE PROYECCIONES COMPACTAS DE LOS DATOS.

- REDUCCIÓN DE DIMENSIONALIDAD
  - APRENDIZAJE MÚLTIPLE
    - SOM
    - TSNE
  - BASADO EN MODELOS
    - LDA
  - FACTORIZACIÓN MATRIARCAL
    - PCA
    - SVD