+34 691 225 633
Rev. Febrero 2024

Autor:
Ronie Martínez

Herramientas para manipulación y análisis de datos

Introducción

En la era digital actual, la cantidad de datos generados diariamente es asombrosa. Desde transacciones financieras hasta interacciones en redes sociales, cada acción en línea deja una huella digital. En este contexto, la habilidad para manipular y analizar datos se ha convertido en un activo invaluable para profesionales en diversos campos. En el corazón de esta capacidad se encuentran conceptos fundamentales como bases de datos, lenguajes de consulta (SQL y NoSQL), APIs, webservices y scripting.

Palabras clave

Bases de datos, SQL y NoSQL, API, webservices, scripting.

Reto

Debido al crecimiento exponencial de los datos, es importante explorar diversas herramientas, marcos de trabajo y plataformas que nos permitan realizar manipulación y análisis sobre estos. En este tema se abordarán varios de estos conceptos fundamentales mediante definiciones y comparaciones.

Desarrollo

En la ciencia de datos y big data, la manipulación de datos se puede utilizar de diversas maneras. Los datos deben organizarse para que las máquinas puedan leerlos e interpretarlos, mientras que, por otro lado, es necesario enseñar a las personas a utilizarlos. Dado que la cantidad de datos consumidos y almacenados aumenta exponencialmente, esto es más crucial que nunca.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Todas las industrias tienen un impacto directo en el funcionamiento de las organizaciones debido a la capacidad de adquirir conocimiento. Para que las computadoras funcionen correctamente, los datos estructurados, o los datos a los que solo pueden acceder las computadoras, deben seguir un patrón.

Después de que los datos hayan sido procesados y modificados para proporcionar información útil, los humanos deben limpiar y mapear los datos, todo esto, a medida que se procesan y utilizan más datos.

El proceso de organizar los datos para hacerlos más comprensibles se conoce como manipulación de datos. Para facilitar la comprensión, cualquier tipo de datos puede ordenarse siguiendo algún criterio de conveniencia (por ejemplo, alfabéticamente, por categorías, etc.). Puede ser difícil encontrar a una persona específica en una empresa si la información de los empleados no está organizada. Se puede ordenar alfabéticamente toda la información de los empleados, lo que facilita el acceso a la información individual de cada empleado. Esto permite a los propietarios de sitios web hacer un seguimiento del tráfico y de los sitios más populares, y los registros del servidor web suelen utilizarlo.

Esta técnica es utilizada por los usuarios de contabilidad para ordenar los datos con el fin de determinar los costos de producción, las futuras obligaciones fiscales, las tendencias de precios, etc. Ayuda a los expertos en previsión bursátil a predecir el rendimiento de las acciones en el futuro. Además, puede usarse para mostrar datos de manera más realista en formatos de datos, código de software o páginas web. Los programas informáticos, las páginas web o el formato de datos determinado por el usuario pueden modificar los datos para que sean más fáciles de entender (Ortega, 2023).

Bases de datos

Las bases de datos desempeñan un papel crítico y un pilar fundamental en la manipulación y almacenamiento de datos, proporcionando un marco estructurado y eficiente para almacenar, gestionar y acceder a grandes volúmenes de datos. La comprensión profunda de las bases de datos relacionales, respaldadas por el lenguaje SQL, ofrecen una estructura organizada y tabular, además, permite a los profesionales diseñar esquemas eficientes, normalizar datos, realizar análisis avanzados, ejecutar consultas complejas, descubrir patrones, entrenar modelos de aprendizaje automático y extraer información valiosa para la toma de decisiones. Esta semana, exploraremos cómo optimizar el rendimiento de las consultas, relacionar e integrar diversos conjuntos de datos,

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

implementar transacciones seguras y diseñar esquemas que se adapten a las necesidades específicas de cada aplicación.

Además, nos sumergiremos en las bases de datos NoSQL, explorando su flexibilidad para manejar datos no estructurados. Analizaremos casos de uso específicos para bases de datos de documentos, grafos y clave-valor, proporcionando a los estudiantes una perspectiva completa de las opciones disponibles en el panorama de almacenamiento de datos.

Lenguajes de consulta (SQL y NoSQL)

El lenguaje de consulta SQL (Structured Query Language) es un lenguaje estándar diseñado para gestionar y manipular bases de datos relacionales. Se utiliza para definir y manipular datos en sistemas de gestión de bases de datos relacionales (Relational Database Management System – RDBMS), como MySQL, PostgreSQL, SQL Server y Oracle. Permite realizar operaciones como consultas, inserciones, actualizaciones y eliminaciones de datos de manera eficiente.

Como características principales se tienen:

- **Tablas Relacionales:** Los datos se almacenan en tablas relacionadas entre sí. Las relaciones entre entidades de datos pueden ser eficientemente establecidas usando claves foráneas (foreign keys), habilitando consultas sofisticadas y asegurando la coherencia de los datos.
- **Esquemas Predefinidos:** Al seguir un modelo de datos estructurado, se define la estructura de los datos antes de insertarlos. Lo que a su vez ayuda a la integración, gestión y organización de contenidos en plataformas CMS (Content Management Systems).
- **Transacciones:** Permite operaciones atómicas, consistentes, aisladas y duraderas (Atomicity, Consistency, Isolation, Durability – ACID). Garantiza la consistencia de los datos y previene la pérdida y corrupción de datos.
- **Ecosistema maduro:** Al haber sido utilizadas durante décadas, se tiene como resultado un ecosistema robusto en cuanto a herramientas, marcos de trabajo (frameworks) y documentación extensa.

Por otro lado, se tienen las bases de datos NoSQL o "Not Only SQL" que es un término que engloba diversas tecnologías de bases de datos que no siguen el modelo relacional tradicional. No impone esquemas fijos y es más flexible en

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

el manejo de datos no estructurados o semiestructurados, como MongoDB o Cassandra, que ofrecen enfoques alternativos para casos donde la flexibilidad y escalabilidad son prioritarias. Sin embargo, la integridad de los datos es algo a considerar, ya que se pueden requerir comprobaciones adicionales a nivel de aplicación.

Como características principales se tienen:

- **Esquemas Dinámicos:** No requiere una estructura de datos predefinida. Permite a los desarrolladores adaptarse a los requisitos de datos cambiantes sin la necesidad de migraciones complejas.
- **Escalabilidad Horizontal:** Se puede escalar fácilmente añadiendo más nodos al sistema y no necesariamente añadiendo más recursos en un solo lugar. Esto permite manejar volúmenes de datos masivos para aplicaciones de crecimiento impredecible.
- **Tipos de Datos Variados:** Admite diferentes tipos de datos, como documentos (JSON o BSON), clave-valor, grafos, etc.
- **Diseño:** Prioriza consistencia, disponibilidad o tolerancia de partición, basado en el teorema CAP (Consistency, Availability, or Partition Tolerance).

Las diferencias más importantes se presentan en la Tabla 1, y hay que considerar que la elección entre SQL y NoSQL depende de los requisitos específicos del proyecto, la complejidad de los datos y las necesidades de escalabilidad (CodeAutomation, 2023; MongoDB, 2023; Smallcombe, 2023).

TABLA 1. COMPARACIÓN ENTRE SQL Y NOSQL.

	SQL	NoSQL
Modelo de datos	Datos organizados en tablas relacionadas.	Datos almacenados en formatos flexibles como documentos, grafos o clave-valor.
Escalabilidad	Escalabilidad vertical (más recursos en una única máquina).	Escalabilidad horizontal (añadir más máquinas).
Esquemas	Esquema fijo y riguroso.	Esquema dinámico o inexistente.
Almacenamiento	Los datos son almacenados en tablas con filas y columnas	Los datos son almacenados en colecciones o documentos.
Transacciones	ACID (Atomicidad, Consistencia, Aislamiento, Durabilidad).	Puede variar; no todos cumplen con ACID.
Ejemplos de aplicación	Sistemas donde la integridad de los datos es crítica (por ejemplo, sistemas financieros).	Aplicaciones que requieren escalabilidad y flexibilidad, en donde no se requieran datos estructurados (por ejemplo, entornos de redes sociales, Big Data, IoT, etc.)
Gestores	MySQL, PostgreSQL, Oracle, SQL Server, Microsoft SQL Server.	MongoDB, Cassandra, Couchbase, Amazon DynamoDB, Redis.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Entre los factores a tomar en cuenta para seleccionar el sistema de base de datos apropiado están:

- **Estructura de datos:** Analizar el modelo de datos y determinar si se beneficia de una estructura rígida (SQL) o requiere la flexibilidad de datos sin estructura (NoSQL).
- **Necesidades de escalabilidad:** Evaluar el potencial de crecimiento de la aplicación y evaluar si el escalado horizontal (NoSQL) o el escalado vertical (SQL) se alinea mejor con los requisitos a largo plazo.
- **Consistencia vs. flexibilidad:** Identificar la importancia de la consistencia de los datos y si la aplicación puede tolerar cierta flexibilidad en estos.
- **Comunidad y soporte:** Considerar la madurez del sistema de base de datos, la documentación disponible y el tamaño de la comunidad de desarrolladores que lo rodea.

APIs y Servicios Web

La interconexión de sistemas se logra a través de APIs (Application Programming Interfaces) y servicios web. Estos mecanismos permiten la transferencia de datos entre aplicaciones de manera segura y eficiente. Comprender cómo consumir y proporcionar datos a través de APIs se ha vuelto esencial en el entorno tecnológico actual.

Una API es un conjunto de reglas y definiciones que permite que una aplicación se comunique con otra. Proporciona un conjunto de funciones y procedimientos que permiten la creación de aplicaciones y facilitan la interacción entre diferentes componentes de software.

Un cliente realiza una solicitud HTTP (HyperText Transfer Protocol) a una API en algún punto al que tiene acceso. La API valida la solicitud y la pasa al servidor o aplicación de destino. El servidor devuelve una respuesta, primero a través de la API, quien luego la transfiere al cliente. La API proporciona seguridad al desacoplar la aplicación consumidora de la infraestructura que proporciona el servicio. Una vez que un servicio API y un cliente intercambian claves de autenticación, se comunican a través de la API, lo que significa que no tienen acceso completo entre sí, pero se puede pasar suficiente información de forma segura para realizar el trabajo. Un cliente puede emitir ciertos tipos de solicitudes de protocolo HTTP, de los cuales existen cuatro tipos principales:

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

- **GET:** esta solicitud lee información de un registro en la base de datos.
- **PUT:** esta solicitud cambia la información de un registro en la base de datos.
- **POST:** esta solicitud crea un nuevo registro en la base de datos.
- **ELIMINAR:** esta solicitud elimina un registro de la base de datos.

Técnicamente, lo anterior describe el uso de API web, que es otra razón por la que se mezclan las API y los servicios web. Sin embargo, las APIs pueden existir fuera de la web y lo han hecho desde que las computadoras se conectaron entre sí por primera vez. La distinción importante es que las API se utilizan para vincular aplicaciones, y aunque hoy en día eso generalmente se hace a través de HTTP o HTTPS, no siempre fue así.

Como características principales, se tienen:

- **Interoperabilidad:** Permite a aplicaciones de diferentes proveedores interactuar entre sí.
- **Abstracción de Funcionalidades:** Oculta la complejidad interna y expone solo las funciones necesarias.
- **Documentación:** Incluye información detallada sobre cómo utilizar la API.

Un webservice es un conjunto de protocolos y estándares que permite la comunicación entre sistemas y máquinas a través de la web. Utiliza protocolos como HTTP para facilitar la transmisión de datos y se basa en estándares como XML (eXtensible Markup Language) o JSON (JavaScript Object Notation) para estructurar la información que se intercambia entre las aplicaciones.

Como características principales, se tiene:

- **Acceso Remoto:** Permite el acceso a funciones o datos en un servidor remoto.
- **Estándares Abiertos:** Utiliza estándares como SOAP (Simple Object Access Protocol) o REST (REpresentational State Transfer).
- **Escalabilidad:** Puede manejar grandes volúmenes de tráfico y peticiones.

Una comparación se presenta en la Tabla 2, y como resumen, mientras que una API es un conjunto general de reglas para la interacción entre aplicaciones, un webservice es una implementación específica de estas reglas que permite la comunicación entre sistemas a través de la web, utilizando protocolos y estándares específicos.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

TABLA 2. COMPARACIÓN ENTRE API Y WEBSERVICE

	API	Webservice
Propósito	Define cómo las aplicaciones deben interactuar.	Facilita la comunicación entre sistemas a través de la web.
Protocolos	Puede utilizar diversos protocolos, incluidos HTTP, RPC (Remote Procedure Call), etc.	Utiliza protocolos específicos como SOAP o REST.
Formato de datos	Puede usar diversos formatos de datos, como JSON o XML.	Frecuentemente utiliza XML para estructurar los datos (aunque RESTful webservices también pueden usar JSON).
Uso típico	Puede referirse a cualquier interfaz de programación, incluyendo bibliotecas de funciones en un lenguaje específico.	Se refiere específicamente a servicios web que siguen protocolos y estándares.
Ejemplos prácticos	Google Maps API, Twitter API.	RESTful Web Service para acceder a datos de usuarios (GET, POST, PUT, DELETE), SOAP service para integración empresarial.

Cada servicio web es una API ya que expone los datos y/o la funcionalidad de una aplicación, pero no toda API es un servicio web. Las APIs son solo los terminales que permiten las relaciones cliente-servidor, mientras que los servicios web son un estilo arquitectónico para integrar aplicaciones web que utilizan los estándares abiertos XML, SOAP y WSDL (Web Services Description Language) a través de una red troncal de protocolo de Internet. XML es el formato de datos utilizado para contener los datos y proporcionar metadatos a su alrededor, SOAP se utiliza para transferir los datos y WSDL se utiliza para describir los servicios disponibles. Es muy común que las API y los servicios web se confundan ya que tienen mucho que ver entre sí (Jagger, 2023).

Scripting para manipulación de datos

El scripting para la manipulación de datos es un proceso esencial para cambiar o alterar datos con el fin de hacerlos más legibles, organizados y útiles. Este proceso puede incluir operaciones como filtrado de filas y columnas, agregación, combinación, concatenación, entre otros. Los lenguajes de scripting son ampliamente utilizados en la manipulación de datos, ya que están diseñados para realizar tareas específicas y automatizar procesos en entornos determinados, como: la creación y el mantenimiento de sitios web, la generación de contenido dinámico, la interacción con bases de datos, la

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

automatización de tareas en sistemas operativos, el desarrollo de aplicaciones móviles y de escritorio, etc.

El uso de lenguajes de scripting, como Python o R, facilita la manipulación, transformación y análisis eficiente de grandes conjuntos de datos. Estos lenguajes son herramientas poderosas para la automatización de tareas repetitivas, creación de scripts personalizados y análisis estadístico, lo que permite ahorrar tiempo y reducir errores, en comparación con enfoques manuales.

Dentro de sus características principales están:

- **Automatización de tareas:** Los scripts facilitan la automatización de tareas repetitivas, como limpieza de datos, conversión de formatos o generación de informes.
- **Manipulación eficiente de datos:** Permite la manipulación eficiente de grandes conjuntos de datos, aplicando operaciones específicas a través de instrucciones codificadas.
- **Análisis Exploratorio de Datos (EDA):** Facilita el EDA al proporcionar herramientas para visualización, estadísticas descriptivas y otras técnicas de análisis exploratorio.
- **Integración con herramientas y librerías específicas:** Se integra fácilmente con librerías especializadas para análisis de datos, como Pandas en Python o tidyverse en R.
- **Flexibilidad y adaptabilidad:** La flexibilidad de los lenguajes de scripting permite adaptarse a diversos tipos de datos y escenarios de manipulación.

Una comparación entre los lenguajes más utilizados, Python y R, se presenta en la Tabla 3, y la elección para scripting en manipulación de datos depende de varios factores, incluyendo preferencias personales, requisitos del proyecto, y el contexto en el que se está trabajando. Ambos lenguajes son muy populares en el ámbito de la ciencia de datos y manipulación de datos.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

TABLA 3. COMPARACIÓN ENTRE PYTHON Y R

	Python	R
Utilización	Ampliamente utilizado para scripting en manipulación y análisis de datos, con librerías como Pandas y NumPy.	Especialmente popular en estadísticas y análisis de datos, con paquetes como tidyverse.
Sintaxis y enfoque	Sintaxis fácil de aprender, enfoque generalista con amplia aplicabilidad en diversos dominios.	Diseñado específicamente para análisis estadístico, con una sintaxis centrada en manipulación y visualización de datos.
Librerías	Amplio ecosistema de librerías, no solo para manipulación de datos, sino también para aprendizaje automático, visualización y más.	Fuerte enfoque en paquetes especializados para estadísticas y análisis de datos.

Análisis de datos en tiempo real

A medida que se incrementa la cantidad de datos, se requiere un sistema capaz de manejarlos rápidamente. El análisis de datos en tiempo real recopila, procesa y clasifica datos sin apenas retrasos, todo esto con el fin de tomar decisiones de inmediato y elaborar informes que saquen conclusiones a partir de la información.

El análisis de datos en tiempo real puede usarse para una variedad de propósitos, incluida la detección de patrones, incidencias o personalización de la información, detectar incidencias, optimiza los recursos y personalizar la información en tiempo real, ayudando a tomar decisiones ágiles.

Existen varias herramientas y plataformas que pueden ayudar en este proceso (Arias, 2023):

- **Apache Kafka:** Es una plataforma distribuida de streaming de eventos de alto rendimiento y baja latencia que facilita la construcción de arquitecturas de microservicios y el análisis en tiempo real de los flujos de datos.
- **Esper:** Es una plataforma especializada en el Procesamiento de Eventos Complejos (CEP) que permite el procesamiento en tiempo real de eventos y datos, así como el análisis de patrones, anomalías y correlaciones en flujos de datos en tiempo real.
- **Redis:** Es una base de datos en memoria preparada para procesar la información y recuperar la data de manera instantánea y eficiente.
- **TensorFlow Serving:** Es una plataforma de alto rendimiento y flexible que permite introducir el aprendizaje automático en el análisis de datos en

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

tiempo real (entornos de producción), para conseguir una toma de decisiones inteligente e instantánea.

- **Arquitecturas Event-Driven (EDA):** Son sistemas que trabajan con eventos (acciones o cambios de estado significativos) en tiempo real para analizar de forma instantánea la información.

Conclusiones

La manipulación de datos puede utilizarse en la ciencia de datos de diversas maneras. Se utiliza para hacer los datos más comprensibles o estructurados. Los datos se utilizan mejor cuando pueden manipularse con fines de marketing, ventas, contabilidad y atención al cliente. Un análisis de datos adecuado implica reordenar, ordenar, modificar y cambiar los datos.

Las bases de datos son la columna vertebral de los entornos de ciencia de datos y big data. Proporcionan la infraestructura necesaria para almacenar, gestionar y analizar datos a escala, permitiendo a las organizaciones extraer conocimientos valiosos y tomar decisiones informadas en un mundo cada vez más impulsado por datos. La elección entre SQL y NoSQL depende en gran medida de la naturaleza del proyecto y sus requisitos, las características y los requisitos específicos de los datos y las metas a largo plazo. Ambos enfoques ofrecen ventajas y desventajas significativas, y la decisión adecuada dependerá de factores como la estructura de los datos, la escalabilidad, la consistencia y la flexibilidad. Inclusive, en algunos casos, una combinación de ambos enfoques (tecnología políglota) puede ofrecer la mejor solución, aprovechando las fortalezas de cada sistema en diferentes partes del proyecto. La clave reside en entender las necesidades del negocio y de los datos para tomar decisiones informadas sobre la arquitectura de la base de datos.

APIs y webservices son conceptos interrelacionados pero distintos en el ámbito de la comunicación entre sistemas. Ambos juegan un papel crucial en la construcción de aplicaciones modernas y la integración de servicios, pero se diferencian en su alcance y enfoque. Mientras que la API representa un conjunto más amplio de reglas y definiciones que permiten la interacción entre diferentes aplicaciones o componentes de software; no se limita a la comunicación web y puede abarcar cualquier interfaz de programación, incluyendo librerías de funciones en un lenguaje específico; ofrece flexibilidad en la implementación, ya que puede utilizar varios protocolos de comunicación, como HTTP, RPC, entre otros; y puede tener una documentación detallada que

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

guía a los desarrolladores sobre cómo utilizar las funciones proporcionadas. Webservices por su parte es una implementación específica de una API que utiliza protocolos web estándar (como SOAP o REST), para facilitar la comunicación entre sistemas a través de la web; se enfoca específicamente en la comunicación remota mediante la exposición de funciones o servicios a través de URLs; puede seguir estándares abiertos y protocolos bien definidos, facilitando la interoperabilidad entre sistemas heterogéneos; y puede ser RESTful, lo que implica un diseño orientado a recursos y el uso de operaciones HTTP estándar. En última instancia, la elección entre API y webservices dependerá de los requisitos del proyecto, la arquitectura de la aplicación y la naturaleza de la comunicación entre sistemas. Ambos conceptos son esenciales en el desarrollo moderno de software, permitiendo una integración fluida y eficiente de servicios en el vasto ecosistema digital actual.

El scripting para manipulación de datos ofrece una herramienta poderosa para profesionales de datos al facilitar la automatización de tareas, la manipulación eficiente de datos y la exploración detallada de conjuntos de datos. La elección del lenguaje de scripting dependerá de las preferencias individuales y de los requisitos específicos del proyecto, pero en conjunto, estos scripts son esenciales para mejorar la eficiencia y la calidad en el manejo de datos.

Referencias

Arias, A. (2023, agosto 17). *Análisis de datos en tiempo real: Consulta esta guía*. Tokio School. https://www.tokioschool.com/noticias/analisis-datos-tiempo-real/

CodeAutomation. (2023). *Working with Databases in Web Development: SQL vs. NoSQL*. https://www.linkedin.com/pulse/working-databases-web-development-sql-vs-nosql-codeautomationai

Jagger, E. (2023). *What's the Difference Between API and Web Services?* Abstract. https://www.abstractapi.com/guides/api-vs-web-services

MongoDB. (2023). *NoSQL Vs SQL Databases*. MongoDB. https://www.mongodb.com/nosql-explained/nosql-vs-sql

Ortega, C. (2023, febrero 13). Manipulación de datos: Qué es, técnicas y ejemplos. *QuestionPro*. https://www.questionpro.com/blog/es/manipulacion-de-datos/

Smallcombe, M. (2023). *SQL vs NoSQL: 5 Critical Differences*. Integrate.Io. https://www.integrate.io/blog/the-sql-vs-nosql-difference/

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.