+34 691 225 633
Rev. Febrero 2024

Autor:
Ronie Martínez

Preparación y procesamiento de datos

Introducción

La preparación de datos puede ser la parte más importante de un proyecto de aprendizaje automático o ciencia de datos. Es la parte que lleva más tiempo, aunque parece ser el tema menos discutido. La preparación de datos, a veces denominada preprocesamiento de datos, es el acto de transformar datos sin procesar en una forma que sea apropiada para el modelado. Los algoritmos de aprendizaje automático requieren que los datos de entrada sean números y la mayoría de las implementaciones de algoritmos mantienen esta expectativa. Como tal, si los datos contienen tipos de datos y valores que no son números, como etiquetas, se deberán convertir los datos en números. Además, los algoritmos específicos de aprendizaje automático tienen expectativas con respecto a los tipos de datos, la escala, la distribución de probabilidad y las relaciones entre las variables de entrada, y es posible que sea necesario cambiar los datos para cumplir con estas expectativas.

Palabras clave

Procesamiento de datos, limpieza, manipulación, selección de características.

Reto

Los modelos de aprendizaje automático para ciencias de datos se entrenan con valores numéricos, es decir, los datos crudos obtenidos en etapas de recolección de datos necesitan ser preparados y manipulados para cumplir con esta especificación. En este tema se presentan las explicaciones y justificaciones de estos procesos, además de las técnicas utilizadas más comunes.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Desarrollo

Preparación de datos en un proyecto

El principal desafío de la preparación de datos radica en que cada conjunto de datos es único y diferente (proyectos específicos). Los conjuntos de datos difieren en el número de variables (decenas, centenas, miles o más), los tipos de variables (numéricas, nominales, ordinales, booleanas), la escala de las variables, la variación (*drift*) de los valores a lo largo del tiempo, etc. Como tal, esto hace que discutir la preparación de datos sea un desafío. Se utilizan estudios de casos específicos o se centra la atención en los métodos generales que se pueden utilizar en los proyectos. Típicamente, los datos en crudo (*raw data*) no se puede utilizar directamente, debido a las siguientes razones:

- Algoritmos de aprendizaje automático ML (*machine learning*) requieren que los datos sean numéricos.
- Algunos algoritmos de ML imponen ciertos requisitos sobre los datos.
- Es posible que sea necesario corregir el ruido estadístico y los errores en los datos.
- Se pueden extraer relaciones no lineales complejas de los datos.

Los datos deben procesarse previamente antes de usarse para probar y evaluar un modelo de ML. Este paso, en un proyecto de modelado predictivo, se conoce como preparación de datos, aunque tiene muchos otros nombres, como manipulación de datos, limpieza de datos, preprocesamiento de datos e ingeniería de características (*feature engineering*). Algunos de estos nombres pueden encajar mejor como subtareas para el proceso más amplio de preparación de datos. Se puede definir la preparación de datos como la transformación de datos sin procesar a una forma que sea más adecuada para el modelado. De esta manera, las tareas estándar o más comunes que se pueden usar o explorar durante el paso de preparación de los datos son las siguientes:

- **Limpieza de Datos (*data cleaning*):** Identificar y corregir errores en los datos.
- **Selección de características (*feature selection*):** identificar aquellas variables de entrada que son más relevantes para la tarea.
- **Transformaciones de datos (*data transforms*):** cambiar la escala o distribución de variables.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

- **Ingeniería de características (*feature engineering*):** derivar u obtener nuevas variables a partir de los datos disponibles.
- **Reducción de dimensionalidad (*dimensionality reduction*):** Creación de proyecciones compactas de los datos.

Cada una de estas tareas es un campo completo de estudio con algoritmos especializados, por lo que en esta semana se tratará de cubrir estos temas de manera resumida y enfocándose en los puntos más importantes. La filosofía más amplia de la preparación de datos es descubrir cómo exponer mejor la estructura subyacente del problema a los algoritmos de aprendizaje. No se conoce la estructura subyacente del problema; si se la conociera, no se necesitaría un algoritmo de aprendizaje para descubrirlo y aprender a hacer predicciones hábiles. Por lo tanto, exponer la estructura subyacente desconocida del problema es un proceso de descubrimiento, además de descubrir los algoritmos de aprendizaje con mejor rendimiento para el proyecto.

A primera vista, la selección de las técnicas para la preparación de datos es un tema desafiante, pero si se mira el paso de preparación de datos en el contexto de todo el proyecto, se vuelve más sencillo. Los pasos de un proyecto de modelado predictivo antes y después del paso de preparación de datos informan la preparación de datos que puede ser necesaria. El paso previo a la preparación de los datos implica definir el problema. Como parte de la definición del problema, esto puede implicar muchas subtareas, tales como:

- Recopilar datos del dominio del problema.
- Discutir el proyecto con expertos en la materia.
- Seleccionar aquellas variables que se utilizarán como entradas y salidas para un modelo predictivo.
- Revisar los datos que se han recopilado.
- Resumir los datos recopilados utilizando métodos estadísticos.
- Visualizar los datos recopilados mediante gráficos y diagramas.

La información conocida sobre los datos se puede utilizar para seleccionar y configurar métodos de preparación de datos. Por ejemplo, los gráficos de los datos pueden ayudar a identificar si una variable tiene valores atípicos. Esto puede ayudar en las operaciones de limpieza de datos. También puede proporcionar información sobre la distribución de probabilidad que subyace a los datos. Esto puede ayudar a determinar si serían apropiadas las

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

transformaciones de datos que cambian la distribución de probabilidad de una variable. Se pueden utilizar métodos estadísticos, como las estadísticas descriptivas, para determinar si podrían ser necesarias operaciones de escala. Las pruebas de hipótesis estadísticas se pueden utilizar para determinar si una variable coincide con una distribución de probabilidad determinada.

Se pueden utilizar gráficos por pares (*pairwise plot*) y estadísticas para determinar si las variables están relacionadas y, de ser así, en qué medida, proporcionando información sobre si una o más variables son redundantes o irrelevantes para la variable objetivo. Como tal, puede haber mucha interacción entre la definición del problema y la preparación de los datos. También puede haber una interacción entre el paso de preparación de datos y la evaluación de modelos. La evaluación del modelo puede implicar subtareas como:

- Seleccionar una métrica de rendimiento para evaluar la habilidad predictiva del modelo.
- Seleccionar un procedimiento de evaluación del modelo.
- Seleccionar algoritmos para evaluar.
- Ajustar los hiperparámetros del algoritmo.
- Combinar modelos predictivos en conjuntos (*ensembles*).

La información conocida sobre la elección de algoritmos y el descubrimiento de algoritmos de buen rendimiento también puede informar la selección y configuración de los métodos de preparación de datos. Por ejemplo, la elección de algoritmos puede imponer requisitos y expectativas sobre el tipo y la forma de las variables de entrada en los datos. Esto podría requerir que las variables tengan una distribución de probabilidad específica, la eliminación de variables de entrada correlacionadas y/o la eliminación de variables que no están fuertemente relacionadas con la variable objetivo. La elección de la métrica de desempeño también puede requerir una preparación cuidadosa de la variable objetivo para cumplir con las expectativas, como calificar modelos de regresión basados en el error de predicción usando una unidad de medida específica, lo que requiere la inversión de cualquier transformación de escala aplicada a esa variable para modelar. Estos y más ejemplos, resaltan que, si bien la preparación de datos es un paso importante en un proyecto de modelado predictivo, no es un paso independiente. Más bien, está fuertemente influenciado por las tareas realizadas antes y después de la preparación de los datos. Esto resalta la naturaleza altamente iterativa de cualquier proyecto de modelado predictivo.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Importancia de la preparación de datos

En un proyecto de modelado predictivo, los algoritmos de ML aprenden un mapeo de las variables de entrada, a una variable objetivo. La forma más común de proyecto de modelado predictivo implica los llamados datos estructurados o datos tabulares. Se trata de datos tal como se ven en una hoja de cálculo o una matriz, con filas de ejemplos y columnas de características para cada ejemplo. No se pueden adaptar y evaluar algoritmos de ML en datos sin procesar; en cambio, se tienen que transformar los datos para cumplir con los requisitos de los algoritmos.

En álgebra lineal, se puede referir a una tabla de datos como una matriz. La tabla se compone de filas y columnas. Una fila representa un ejemplo del dominio del problema y puede denominarse como: ejemplo, instancia, caso o muestra. Una columna representa las propiedades observadas en el ejemplo y puede denominarse variable, característica o atributo. En este aspecto, las columnas utilizadas para la entrada del modelo se denominan variables de entrada y la columna que contiene el objetivo que se va a predecir se denomina variable de salida. Las filas utilizadas para entrenar un modelo se denominan conjunto de datos de entrenamiento y las filas utilizadas para evaluar el modelo se denominan conjunto de datos de prueba.

Cuando se recopilen los datos, es posible que se tengan que manipular para que formen una tabla grande. Por ejemplo, si se tienen los datos en una base de datos relacional, es común representar entidades en tablas separadas en lo que se conoce como forma normal para minimizar la redundancia. Para crear una tabla grande con una fila por tema o entidad que desea modelar, es posible que deba revertir este proceso e introducir redundancia en los datos en un proceso denominado desnormalización. Si los datos están en una hoja de cálculo o base de datos, es una práctica estándar extraer y guardar los datos en formato CSV. Se trata de una representación estándar que es portátil, bien comprendida y lista para el proceso de modelado predictivo sin dependencias externas.

Aunque los datos estén representados en una tabla grande de filas y columnas, las variables de la tabla pueden tener diferentes tipos de datos. Algunas variables pueden ser numéricas, como números enteros, valores de punto flotante, rangos, tasas, porcentajes, etc. Otras variables pueden ser nombres, categorías o etiquetas representadas con caracteres o palabras, y algunas pueden ser binarias, representadas con 0 y 1 o Verdadero y Falso. El problema es que, en esencia, los algoritmos de ML operan con datos numéricos. Toman

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

números como entrada y predicen un número como salida. Todos los datos se ven como vectores y matrices, utilizando la terminología del álgebra lineal.

Como tal, los datos sin procesar deben cambiarse antes de entrenar, evaluar y utilizar modelos de ML. A veces, los cambios en los datos pueden gestionarse internamente mediante el algoritmo, pero, por lo general, esto debe ser manejado por el profesional antes del modelado.

Incluso si los datos sin procesar contienen solo números, es probable que se requiera cierta preparación de datos. Hay muchos algoritmos diferentes de para elegir para un proyecto de modelado predictivo determinado. No se puede saber qué algoritmo será el apropiado y mucho menos cuál será el más adecuado para la tarea. Por lo tanto, es una buena práctica evaluar sistemáticamente un conjunto de diferentes algoritmos candidatos y descubrir cuál funciona bien o mejor con los datos. El problema es que cada algoritmo tiene requisitos o expectativas específicos con respecto a los datos. De igual manera, incluso si se preparan los datos para cumplir con las expectativas de cada modelo, es posible que no se obtenga el mejor rendimiento. El desempeño de un algoritmo de ML es tan bueno como los datos utilizados en el entrenamiento.

Técnicas para la preparación de datos

Tareas comunes

Como ya se mencionó, se puede definir la preparación de datos como la transformación de datos sin procesar a una forma que sea más adecuada para el modelado. Sin embargo, hay pasos en un proyecto de modelado predictivo antes y después del paso de preparación de datos que son importantes e informan la preparación de datos que se va a realizar. Se puede saltar de un lado a otro entre los pasos de cualquier proyecto determinado, pero todos los proyectos tienen los mismos pasos generales; ellos son:

- **Paso 1:** Definir el problema.
- **Paso 2:** Preparar los datos.
- **Paso 3:** Evaluar modelos.
- **Paso 4:** Finalizar el modelo.

Existen tareas comunes o estándares que pueden usar o explorar durante el paso de preparación de datos en un proyecto. A medida que se trabaja en

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

múltiples proyectos de modelado predictivo, se ve y se requieren los mismos tipos de tareas de preparación de datos una y otra vez. Estas tareas incluyen:

- Limpieza de Datos.
- Selección de características.
- Transformaciones de datos.
- Ingeniería de características.
- Reducción de dimensionalidad.

Esto proporciona un marco de trabajo aproximado que se puede utilizar para pensar y navegar por diferentes algoritmos de preparación de datos que se pueden considerar en un proyecto determinado con datos estructurados o tabulares.

Limpieza de datos

La limpieza de datos implica solucionar problemas sistemáticos o errores en datos desordenados. La limpieza de datos más útil implica una profunda experiencia en el dominio y podría implicar identificar y abordar observaciones específicas que pueden ser incorrectas. Hay muchas razones por las que los datos pueden tener valores incorrectos, como estar mal escritos, dañados, duplicados, etc. La experiencia en el dominio puede permitir identificar observaciones obviamente erróneas, que sean diferentes de lo esperado (por ejemplo, la altura de una persona igual a 180 m). Una vez que se identifican las observaciones confusas, ruidosas, corruptas o erróneas, se pueden abordar. Esto podría implicar eliminar una fila o una columna. Alternativamente, podría implicar reemplazar las observaciones con nuevos valores. Como tal, existen operaciones generales de limpieza de datos que se pueden realizar, tales como:

- Usar estadísticas para definir datos normales e identificar valores atípicos.
- Identificar columnas que tienen el mismo valor o ninguna varianza y eliminarlas.
- Identificar filas duplicadas de datos y eliminarlas.
- Marcar valores vacíos como faltantes.
- Imputar o completar valores faltantes utilizando estadísticas o un modelo aprendido.

La limpieza de datos es una operación que normalmente se realiza primero, antes de otras operaciones de preparación de datos.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

ILUSTRACIÓN 1. RESUMEN DE LA LIMPIEZA DE DATOS

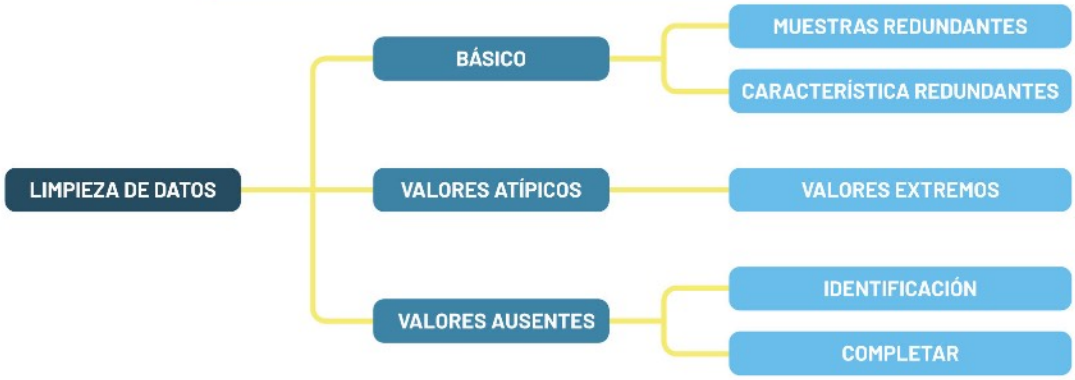

Selección de características

La selección de características se refiere a técnicas para seleccionar un subconjunto de características de entrada que son más relevantes para la variable objetivo que se predice. Esto es importante ya que las variables de entrada irrelevantes y redundantes pueden distraer o engañar a los algoritmos de aprendizaje, lo que posiblemente resulte en un menor rendimiento predictivo. Además, es deseable desarrollar modelos utilizando únicamente los datos necesarios para hacer una predicción, es decir, favorecer el modelo más simple posible con buen rendimiento. Las técnicas de selección de características generalmente pueden agruparse en aquellas que utilizan la variable objetivo (supervisadas) y aquellas que no (no supervisadas). Además, las técnicas supervisadas se pueden dividir en modelos que seleccionan automáticamente características como parte del ajuste del modelo (intrínsecas), aquellas que eligen explícitamente características que dan como resultado el modelo de mejor rendimiento (*wrapper*) y aquellas que califican cada característica de entrada y permiten seleccionar un subconjunto (filtro).

Los métodos estadísticos, como la correlación, son populares para calificar las características de entrada. Las características se pueden clasificar según sus puntuaciones y utilizar un subconjunto con las puntuaciones más altas como entrada para un modelo. La elección de la medida estadística depende de los tipos de datos de las variables de entrada. Además, existen diferentes casos de uso de selección de características comunes que se pueden encontrar en un proyecto de modelado predictivo como:

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

- Entradas categóricas para una variable objetivo de clasificación.
- Entradas numéricas para una variable objetivo de clasificación.
- Entradas numéricas para una variable objetivo de regresión.

Como alternativa, se puede utilizar un método contenedor, como el popular método de eliminación de características recursivas (RFE *Recursive Feature Elimination*), que es independiente del tipo de variable de entrada.

ILUSTRACIÓN 2. RESUMEN DE LA SELECCIÓN DE CARACTERÍSTICAS

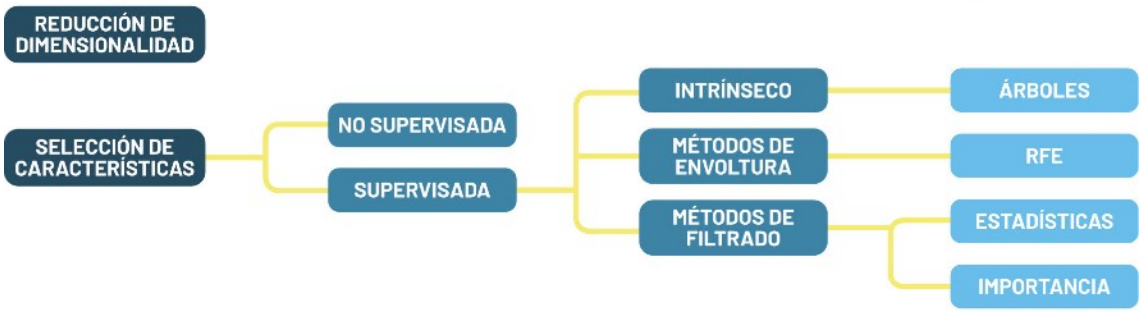

Transformación de datos

Las transformaciones de datos se utilizan para cambiar el tipo o la distribución de las variables de datos. Se trata de un amplio abanico de técnicas diferentes y pueden aplicarse con la misma facilidad a variables de entrada y de salida. Los datos pueden tener varios tipos:

- **Tipo de datos numéricos:** valores numéricos.
  - **Entero:** Enteros sin parte fraccionaria.
  - **Flotante:** Valores con decimales.
- **Tipo de datos categóricos:** valores de etiqueta.
  - **Ordinal:** Etiquetas con un orden de clasificación.
  - **Nominal:** Etiquetas sin orden de clasificación.
  - **Booleano:** Valores Verdadero y Falso.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Es posible que se desee convertir una variable numérica en una variable ordinal en un proceso llamado discretización. Alternativamente, se puede codificar una variable categórica como números enteros o variables booleanas, lo que se requiere en la mayoría de las tareas de clasificación. Una consideración importante con las transformaciones de datos es que las operaciones generalmente se realizan por separado para cada variable.

ILUSTRACIÓN 3. RESUMEN DE TRANSFORMACIÓN DE DATOS

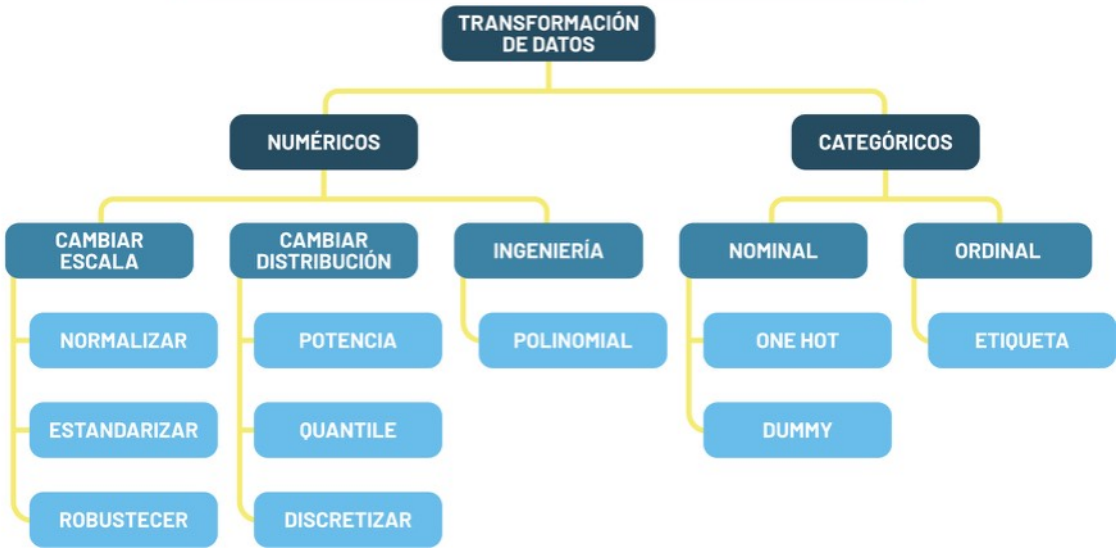

Ingeniería de características

La ingeniería de características se refiere al proceso de creación de nuevas variables de entrada a partir de los datos disponibles. La ingeniería de nuevas funciones es muy específica de sus datos y tipos de datos. Como tal, a menudo requiere la colaboración de un experto en la materia para ayudar a identificar nuevas características que podrían construirse a partir de los datos. Esta especialización hace que sea un tema difícil de generalizar a métodos generales. Sin embargo, existen algunas técnicas que se pueden reutilizar, como, por ejemplo:

- Agregar una variable booleana para algún estado (bandera).
- Agregar un grupo o una estadística de resumen global, como una media.
- Agregar nuevas variables para cada componente de una variable compuesta, como una fecha y hora.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Reducción de dimensionalidad

El número de características de entrada para un conjunto de datos puede considerarse la dimensionalidad de los datos. Por ejemplo, dos variables de entrada juntas pueden definir un área bidimensional donde cada fila de datos define un punto en ese espacio. Esta idea se puede ampliar a cualquier número de variables de entrada para crear grandes hipervolúmenes multidimensionales. El problema es que cuantas más dimensiones tenga este espacio (por ejemplo, más variables de entrada), más probable será que el conjunto de datos represente una muestra muy escasa y probablemente no representativa de ese espacio. Esto se conoce como la maldición de la dimensionalidad.

Esto motiva la selección de características, aunque una alternativa a la selección de características es crear una proyección de los datos en un espacio de dimensiones inferiores que aún conserve las propiedades más importantes de los datos originales. Esto se conoce generalmente como reducción de dimensionalidad y proporciona una alternativa a la selección de características. A diferencia de la selección de características, las variables de los datos proyectados no están directamente relacionadas con las variables de entrada originales, lo que dificulta la interpretación de la proyección.

ILUSTRACIÓN 4. RESUMEN DE REDUCCIÓN DE DIMENSIONALIDAD

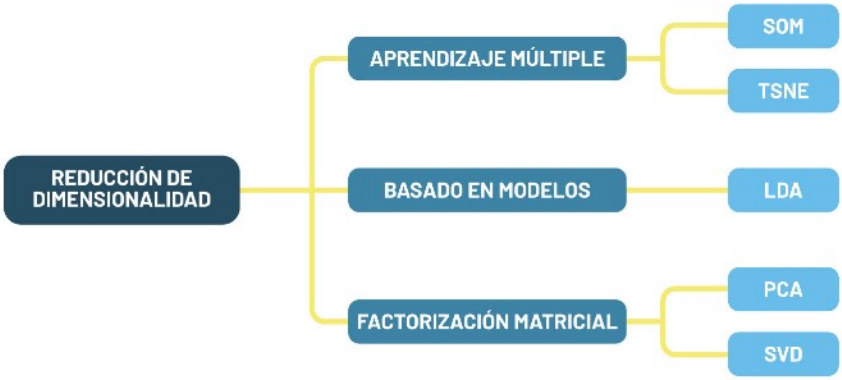

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Conclusiones

La preparación de datos puede ser considerada una parte vital en proyectos de aprendizaje automático o ciencia de datos. Es un proceso complejo que puede llevar bastante tiempo, aunque muchas veces es el que menos se considera y discute. La preparación de datos también se la conoce como manipulación de datos, limpieza de datos, preprocesamiento de datos e ingeniería de características (*feature engineering*). Algunos de estos nombres pueden encajar mejor como subtareas para el proceso más amplio de preparación de datos. En general, es el acto de transformar datos sin procesar en una forma que sea apropiada para el modelado. Los algoritmos de aprendizaje automático requieren que los datos de entrada sean numéricos y la mayoría de las implementaciones de algoritmos mantienen esta expectativa.

Se descubrió cómo considerar la preparación de datos como un paso en un proyecto más amplio de aprendizaje automático de modelado predictivo y/o ciencia de datos. Cada proyecto de modelado predictivo con aprendizaje automático es diferente, pero se realizan pasos comunes en cada proyecto. La preparación de datos implica exponer mejor la estructura subyacente desconocida del problema a los algoritmos de aprendizaje. Los pasos antes y después de la preparación de datos en un proyecto pueden informar qué métodos de preparación de datos aplicar, o al menos explorar.

Los datos estructurados en el aprendizaje automático constan, generalmente, de filas y columnas. La preparación de datos es un paso obligatorio en cada proyecto de aprendizaje automático. La rutina de los algoritmos de aprendizaje automático significa que la mayor parte del esfuerzo de cada proyecto se dedica a la preparación de datos.

La preparación de datos es un paso importante en un proyecto de modelado predictivo, no es un paso independiente, más bien está fuertemente influenciado por las tareas realizadas antes y después de la preparación de los datos. Esto resalta la naturaleza altamente iterativa de cualquier proyecto de modelado predictivo.

Técnicas como la limpieza de datos pueden ayudar a identificar y corregir errores en los datos, como valores perdidos. La transformación de los datos ayuda a cambiar la escala, el tipo, la distribución de probabilidad en el conjunto de datos. Técnicas como la selección de características y la reducción de dimensionalidad pueden reducir el número de variables de entrada.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.

Se presentaron las tareas más comunes de preparación de datos realizadas en una tarea de aprendizaje automático de modelado predictivo. Las técnicas, como la limpieza de datos, pueden identificar y corregir errores en datos como valores faltantes. Las transformaciones de datos pueden cambiar la escala, el tipo y la distribución de probabilidad de las variables en el conjunto de datos. Técnicas como la selección de características y la reducción de dimensionalidad pueden reducir la cantidad de variables de entrada.

El objetivo de la ingeniería de características es agregar un contexto más amplio a una sola observación o descomponer una variable compleja, ambos en un esfuerzo por proporcionar una perspectiva más sencilla de los datos de entrada. Algunos autores consideran la ingeniería de características como un tipo de transformación de datos, aunque sería igualmente razonable pensar en las transformaciones de datos como un tipo de ingeniería de características.

Referencias

Brownlee, J. (2020). *Data Preparation for Machine Learning Data Cleaning, Feature Selection, and Data Transforms in Python*. Machine Learning Mastery.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG.