Autor: Iván García Santillán

Algoritmos predictivos de clasificación: redes neuronales artificiales

Introducción

Una red neuronal artificial (RNA), o artificial neural network (ANN), es un modelo de aprendizaje automático inspirado en el funcionamiento del cerebro humano. Está compuesta por unidades de procesamiento llamadas neuronas artificiales o nodos, que están organizadas en capas interconectadas.

Las redes neuronales artificiales son utilizadas para abordar una amplia variedad de tareas de aprendizaje automático, incluyendo clasificación, regresión, procesamiento de imágenes, procesamiento de lenguaje natural y más.

Por ejemplo, en el campo de la visión por computadora, son esenciales para el reconocimiento de imágenes y rostros, permitiendo innovaciones como los sistemas de seguridad biométrica y las aplicaciones de filtros en redes sociales. En el procesamiento del lenguaje natural, impulsan traductores automáticos y asistentes virtuales, facilitando la comunicación y la interacción con la tecnología. En el sector financiero, estas redes se utilizan para la predicción de series temporales en mercados bursátiles y para la detección de fraudes, analizando patrones complejos en transacciones.

En medicina, contribuyen significativamente en el diagnóstico y pronóstico de enfermedades, analizando datos médicos y patrones en imágenes diagnósticas como radiografías y resonancias magnéticas. Además, en el transporte y ámbito del vehículo autónomo, son fundamentales para la interpretación de los datos sensoriales y la toma de decisiones en tiempo real.

Aunque también se debe considerar algunas desventajas del algoritmo como la baja velocidad de entrenamiento, uso de memoria medio o alto, considerable afinamiento requerido y la baja interpretabilidad de sus resultados ya que son considerados como cajas negras. A pesar de esto, las RNA son muy versátiles

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

para cualquier tipo de aplicación con buenos resultados. Por lo que su uso es muy extendido en el mundo de la ciencia de datos e IA, considerando que son la base de otros algoritmos más complejos de Deep Learning.

A continuación, se detallan el funcionamiento del algoritmo y un ejemplo en Python, Keras y TensorFlow para la predicción del cáncer de mama utilizando un data set público.

Contenido

Una red neuronal artificial es un modelo de aprendizaje automático inspirado en el funcionamiento del cerebro humano. Algunos conceptos clave relacionados con las redes neuronales artificiales son los siguientes (Berzal, 2019):

Neuronas Artificiales: cada neurona artificial es una unidad de procesamiento que toma una serie de entradas, las procesa y produce una salida. Las entradas se multiplican por pesos, se suman y se pasa el resultado a una función de activación.

Función de activación: introduce no linealidad en la red, permitiendo que las redes neuronales aprendan relaciones y patrones complejos en los datos. Existen varias funciones de activación comunes utilizadas en las redes neuronales, entre las que se incluyen: Sigmoide, ReLU, Tangente Hiperbólica, etc. La elección de la función de activación depende del tipo de problema y la arquitectura de la RNA. La función de activación juega un papel fundamental en la capacidad de la RNA para aprender y generalizar a partir de los datos de entrenamiento.

Capas: las neuronas se organizan en capas. Una red neuronal típica consta de una capa de entrada, una o más capas ocultas y una capa de salida. Las capas ocultas permiten a la red aprender representaciones intermedias y abstraer características de los datos.

Conexiones: cada neurona en una capa está conectada a todas las neuronas de la capa anterior y a todas las de la capa siguiente. Estas conexiones tienen pesos que se ajustan (aprenden) durante el proceso de entrenamiento.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Entrenamiento: el entrenamiento de una red neuronal implica el ajuste de los pesos de las conexiones para que la red pueda hacer predicciones precisas. Esto se hace utilizando algoritmos de optimización y un conjunto de datos de entrenamiento que contiene ejemplos de entrada y las salidas deseadas (etiquetas).

Función de Costo: la función de costo mide la discrepancia (error) entre las predicciones de la red y las salidas reales (ground truth) en el conjunto de entrenamiento. El objetivo del entrenamiento es minimizar esta función de costo.

Backpropagation: es un algoritmo utilizado para propagar el error desde la capa de salida hacia atrás a través de la red, ajustando los pesos de las conexiones en función del error cometido.

Arquitectura: las redes neuronales pueden tener diferentes arquitecturas, como redes neuronales feed-forward (Figura 23), redes neuronales recurrentes (RNN) y redes neuronales convolucionales (CNN), cada una adaptada a tareas específicas. En este curso veremos las primeras, conocida como MLP (multi-layer perceptron).

Figura 23. Arquitectura típica de una red neuronal artificial

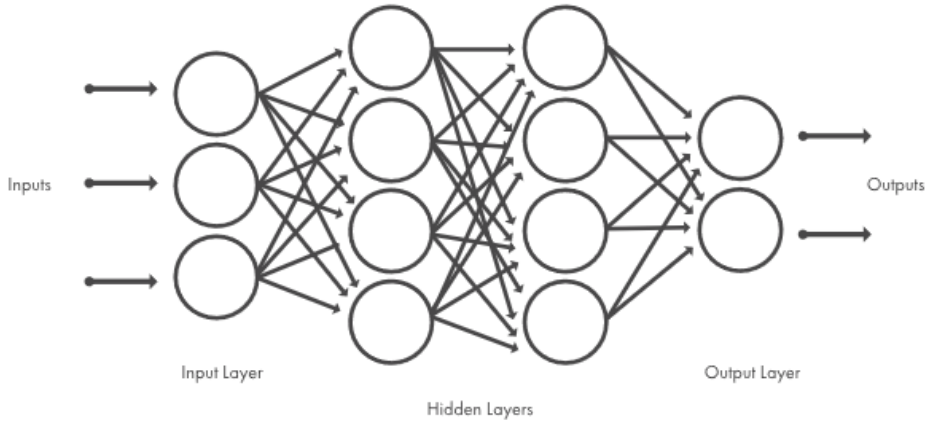

Las redes neuronales artificiales se han destacado en una amplia gama de aplicaciones, incluyendo el procesamiento de imágenes, el procesamiento de lenguaje natural, la visión por computadora, la traducción automática, el reconocimiento de voz, la recomendación de contenido y muchas otras. Su capacidad para aprender representaciones complejas y realizar tareas

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

sofisticadas las ha convertido en un componente esencial del campo de la inteligencia artificial y el aprendizaje automático. En general, el ciclo de vida de un modelo de red neuronal artificial se muestra en la Figura 24.

Figura 24. Ciclo de vida de un modelo de red neuronal artificial

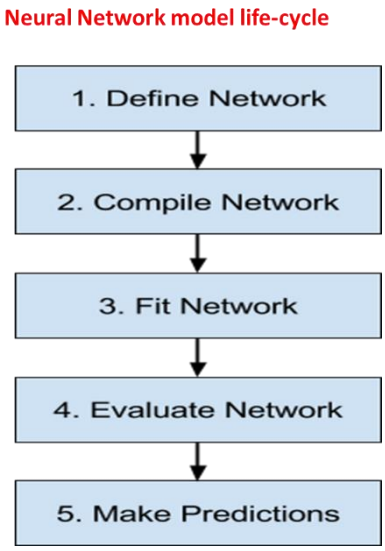

A continuación, se presenta un ejemplo del algoritmo RNA en Python, Keras y TensorFlow para la predicción del cáncer de mama (benigno=0, maligno=1) utilizando el conjunto de datos Breast Cancer Wisconsin (Diagnostic) disponible en la librería scikit-learn.

```
# RNA for breast cancer

from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import MinMaxScaler
from sklearn.metrics import classification_report
from keras.models import Sequential
from keras.layers.core import Dense

# Carga el conjunto de datos Breast Cancer
dataset = load_breast_cancer()
X = dataset.data # 569x30
y = dataset.target # 569x1
```

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

```
# Divide el conjunto de datos en entrenamiento y prueba
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Normaliza los datos para que tengan una escala similar
scaler = MinMaxScaler(feature_range=(0,1)) # [0, 1]
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

# Crea y entrena el modelo RNA
model = Sequential()
model.add(Dense(10, activation='relu', input_dim=30))
model.add(Dense(1, activation='sigmoid'))

model.compile(loss='binary_crossentropy',
              optimizer='adam',
              metrics=['accuracy'])

model.fit(X_train, y_train, epochs=100)

# Realiza predicciones usando el conjunto de prueba
y_pred = model.predict(X_test)

# Convierte las probabilidades en etiquetas binarias (0 o 1)
y_pred = (y_pred > 0.5)

# Muestra el informe de evaluación del modelo entrenado
print(classification_report(y_test, y_pred))

# Matriz de confusión:
from sklearn.metrics import confusion_matrix
import seaborn as sns
import matplotlib.pyplot as plt

cm = confusion_matrix(y_test, y_pred)
print("confusion matrix: \n", cm)
# gráfica de la CM
```

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

```
plt.figure(figsize = (8,4))
sns.heatmap(cm, annot=True, fmt='d')
plt.xlabel('Prediction', fontsize = 12)
plt.ylabel('Real', fontsize = 12)
plt.show()

# Exactitud:
from sklearn.metrics import accuracy_score
acc = accuracy_score(y_test, y_pred)
print("accuracy: ", acc)

# Sensibilidad:
from sklearn.metrics import recall_score
recall = recall_score(y_test, y_pred)
print("recall: ", recall)

# Precisión:
from sklearn.metrics import precision_score
precision = precision_score(y_test, y_pred)
print("precision: ", precision)

# Especificidad
# 'specificity' is just a special case of 'recall'.
# specificity is the recall of the negative class
specificity = recall_score(y_test, y_pred, pos_label=0)
print("specificity: ", specificity)

# Puntuación F1:
from sklearn.metrics import f1_score
f1 = f1_score(y_test, y_pred)
print("f1 score: ", f1)

# Área bajo la curva:
from sklearn.metrics import roc_auc_score
auc = roc_auc_score(y_test, y_pred)
print("auc: ", auc)
# Curva ROC
```

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

```
from sklearn.metrics import roc_curve
plt.figure()
lw = 2
plt.plot(roc_curve(y_test, y_pred)[0], roc_curve(y_test, y_pred)[1],
color='darkorange',lw=lw, label='ROC curve (area = %0.2f)' %auc)
plt.plot([0, 1], [0, 1], color='navy', lw=lw, linestyle='--')
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('Receiver Operating Characteristic')
plt.legend(loc="lower right")
plt.show()

# R Score (R^2 coefficient of determination)
from sklearn.metrics import r2_score
R = r2_score(y_test, y_pred)
print("R2: ", R)
```

Los resultados del modelo de RNA se presentan a continuación:

accuracy: 0.97
recall: 0.99
precision: 0.97
specificity: 0.95
f1 score: 0.98
auc: 0.97
R2: 0.89

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

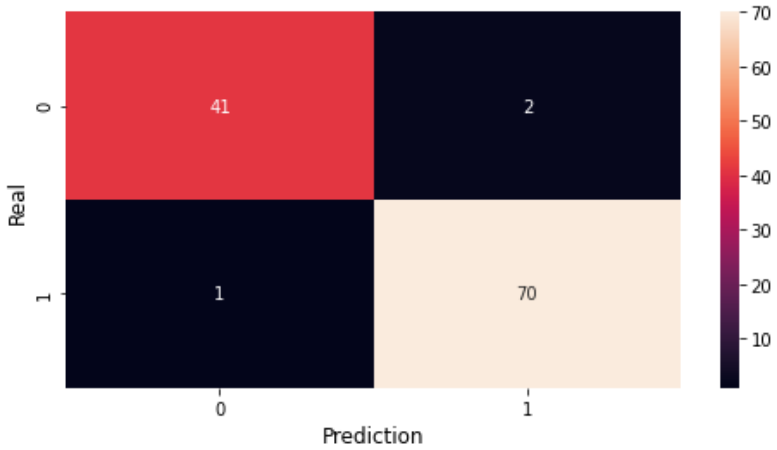

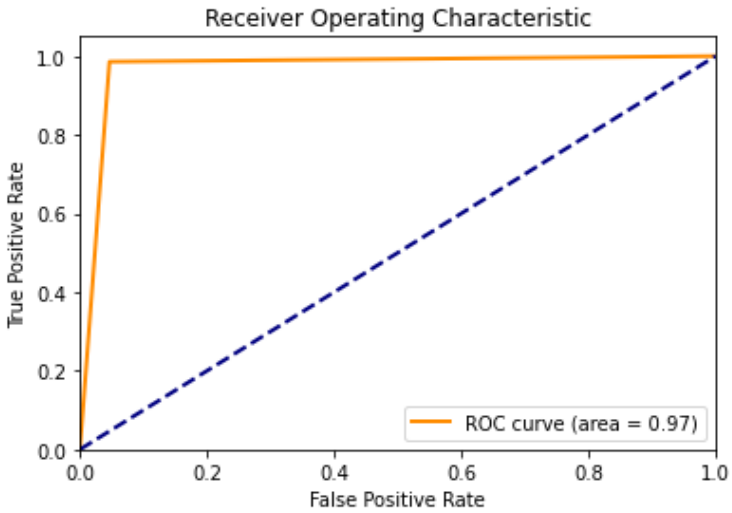

Un clasificador adecuado es aquel que alcanza una exactitud (accuracy) superior al 85 %. Por lo que, este modelo de RNA entrenado cumple con este criterio de calidad.

Adicionalmente, tenga en cuenta que se pueden ajustar varios parámetros del algoritmo (como activation, loss, optimizer, metrics, epochs, etc.) para obtener un modelo óptimo. Revise la documentación (ayuda en línea) del algoritmo para más detalles y experimente con ellos.

Finalmente, aunque la RNA es un modelo fundamental en la caja de herramientas de análisis predictivo, como cualquier otra técnica, presenta tanto ventajas como desventajas que se resumen a continuación:

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Ventajas de las redes neuronales artificiales:

Capacidad de aprendizaje y adaptación: las RNA tienen la capacidad de aprender y modelar relaciones no lineales y complejas, lo que las hace extremadamente potentes para modelar problemas que son difíciles de resolver con técnicas tradicionales. El término "modelar relaciones no lineales" se refiere a la capacidad de un modelo estadístico o de aprendizaje automático para capturar y representar relaciones entre variables que no son simplemente proporcionales o directas. En una relación no lineal, los cambios en una variable no producen cambios proporcionales y predecibles en otra variable, lo que significa que la relación entre variables no puede ser descrita adecuadamente por una línea recta, sino por otro tipo de relación como cuadrática, exponencial, logarítmica, sinusoidal, etc.

Generalización: una vez entrenadas, las redes neuronales son capaces de generalizar a partir de ejemplos no vistos, lo que es crucial para aplicaciones como el reconocimiento de patrones y la clasificación de imágenes.

Manejo de grandes volúmenes de datos: las RNA son eficaces para manejar grandes cantidades de datos y son capaces de identificar patrones y tendencias que pueden no ser evidentes para los humanos u otros algoritmos.

Flexibilidad: pueden ser aplicadas a una amplia gama de industrias y problemas, desde el reconocimiento de voz y facial hasta la predicción de series temporales y análisis de sentimientos.

Soporte para diversos tipos de datos: capaces de procesar datos en diferentes formas, incluyendo imágenes, audio, texto y más, haciendo posible su uso en una variedad de aplicaciones en el mundo real.

Desventajas de las Redes Neuronales Artificiales:

Requieren gran cantidad de datos para el entrenamiento: para funcionar bien, las RNA generalmente requieren grandes conjuntos de datos de entrenamiento, lo que puede ser un desafío en términos de recopilación y procesamiento de datos.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Costosas computacionalmente: el entrenamiento de modelos de redes neuronales puede ser muy demandante en términos de recursos computacionales, especialmente para redes profundas con muchas capas (Deep Learning). Esto puede requerir hardware especializado, como GPUs.

Difíciles de interpretar: a diferencia de otros modelos predictivos (como los árboles de decisión), las RNA son a menudo consideradas como "cajas negras" porque las operaciones internas y la manera en que llegan a una decisión no son fácilmente interpretables.

Sobreajuste: las redes neuronales son propensas al sobreajuste, especialmente si no tienen suficientes datos de entrenamiento o si la arquitectura de la red es demasiado compleja en relación con la simplicidad del problema.

Sensibilidad a la configuración de los parámetros: la configuración de parámetros (como la tasa de aprendizaje, el número de capas, y el número de nodos por capa) puede tener un gran impacto en el rendimiento del modelo, y encontrar la configuración óptima puede ser un proceso laborioso y técnico.

Vulnerabilidad a ataques adversarios: las redes neuronales pueden ser susceptibles a ataques adversarios, en los cuales pequeñas pero intencionadas perturbaciones en los datos de entrada pueden engañar a la red para que haga predicciones incorrectas.

Conclusiones

En esta lectura se ha revisado los fundamentos del algoritmo de red neuronal artificial para abordar problemas de clasificación binaria utilizando Python y TensorFlow-Keras. Las redes neuronales ofrecen un poderoso conjunto de capacidades para el modelado de datos complejos y no lineales, pero también presentan desafíos significativos en términos de necesidades de datos, costos computacionales, y dificultades en la interpretación de sus decisiones. La elección de utilizar redes neuronales debe considerar estos factores en función del problema específico y los recursos disponibles.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Por lo que, se motiva a los estudiantes a revisar material y ejemplos adicionales disponibles libremente en Internet para profundizar en la comprensión del algoritmo y su aplicación eficaz en diferentes problemas de variada complejidad.

Bibliografía

Berzal, Fernando (2019). *Redes neuronales & Deep Learning*. USA: Independently published.

Gerón, A. (2023). *Aprende Machine Learning con Scikit-Learn, Keras y TensorFlow: Conceptos, herramientas y técnicas para conseguir sistemas inteligentes.* Tercera Edición. Anaya Multimedia.

Torres, J. (2020). *Python Deep Learning: Introducción práctica con Keras y TensorFlow 2*. Marcombo.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.