Autor: Iván García Santillán

Análisis exploratorio de datos

Introducción

El análisis exploratorio de datos (EDA por sus siglas en inglés, Exploratory Data Analysis) es una parte fundamental de cualquier proyecto de análisis de datos que tiene varios propósitos importantes, tales como: Comprender los datos, incluyendo la estructura de los datos, sus características, distribuciones, tendencias y patrones subyacentes); Detectar Anomalías y Errores; Seleccionar variables relevantes; Generar hipótesis iniciales sobre relaciones entre variables; Tomar decisiones iniciales sobre cómo abordar el proyecto de análisis de datos (elección de algoritmos), Optimización de recursos eliminando variables irrelevantes o reducir la dimensionalidad de los datos; Preparación para un modelado avanzado, etc.

Aquí se mostrará cómo realizar un análisis exploratorio de datos básico en el conjunto de datos del *Titanic* utilizando Python, centrándonos en estadísticas descriptivas y visualización de datos.

Contenido

Análisis exploratorio de datos (estadísticas y visualización)

En esta lectura se mostrará cómo realizar un análisis exploratorio de datos básico en el conjunto de datos del *Titanic* utilizando Python, centrándonos en estadísticas descriptivas y visualización de datos. Para este ejemplo, asumimos que se tiene el conjunto de datos del *Titanic* en un archivo CSV llamado "titanic.csv".

Primero, debes importar las bibliotecas necesarias, cargar los datos y observar las primeras filas para tener una idea de cómo se ven los datos:

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# Cargar el conjunto de datos del Titanic
titanic_df = pd.read_csv('titanic.csv')

# Ver las primeras filas del conjunto de datos
print(titanic_df.head())
```

A continuación, se obtiene estadísticas descriptivas básicas de las variables numéricas en el conjunto de datos:

```
# Estadísticas descriptivas
print(titanic_df.describe())
```

Para obtener estadísticas de las variables categóricas, se puede utilizar el siguiente código:

```
# Estadísticas de variables categóricas
print(titanic_df.describe(include=['object']))
```

Para visualizar los datos, puedes crear varios tipos de gráficos. Aquí hay algunos ejemplos:

Histogramas de Edades (Figura 7):

```
plt.figure(figsize=(8, 6))
sns.histplot(titanic_df['Age'].dropna(), bins=30, kde=True)
plt.xlabel('Edad')
plt.ylabel('Frecuencia')
plt.title('Distribución de Edades en el Titanic')
plt.show()
```

Figura 7. Distribución de edades en el dataset Titanic

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

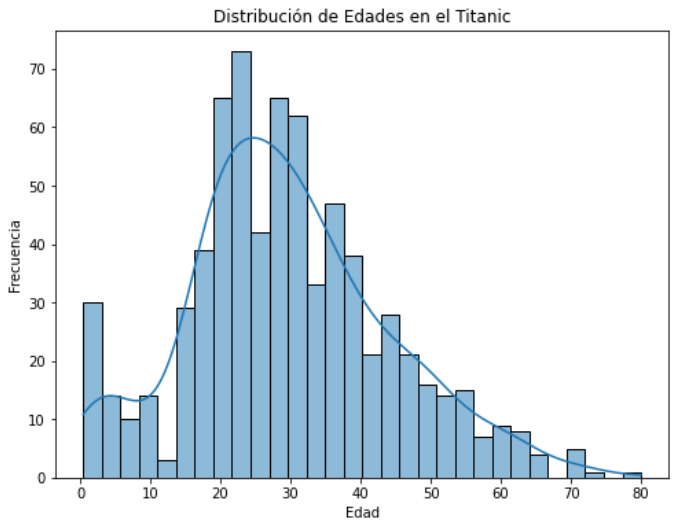

Gráfico de Barras de Supervivencia por Clase (Figura 8):

```
plt.figure(figsize=(8, 6))
sns.countplot(data=titanic_df, x='Pclass', hue='Survived')
plt.xlabel('Clase')
plt.ylabel('Cantidad')
plt.title('Supervivencia por Clase en el Titanic')
plt.legend(title='Sobreviviente', labels=['No', 'Sí'])
plt.show()
```

Figura 8. Supervivencia de pasajeros por clase en el dataset Titanic

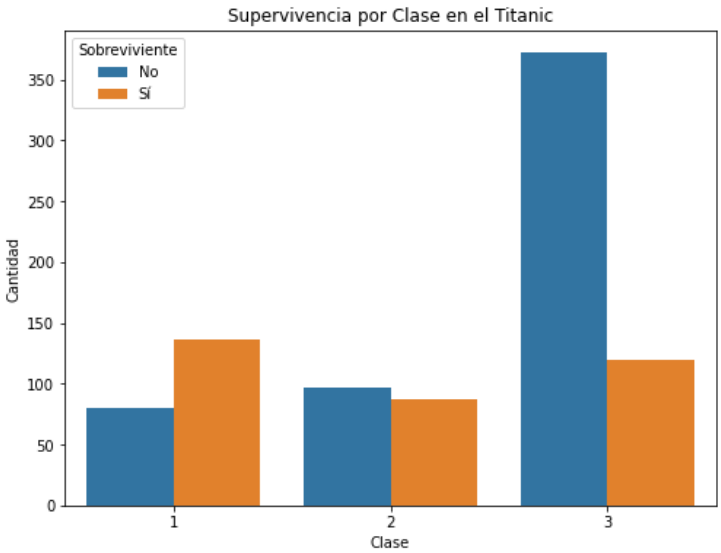

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Gráfico de Torta de Género (Figura 9):

```
plt.figure(figsize=(8, 6))
titanic_df['Sex'].value_counts().plot(kind='pie', autopct='%1.1f%%')
plt.title('Distribución de Género en el Titanic')
plt.ylabel('')
plt.show()
```

Figura 9. Distribución del género de pasajeros en el dataset Titanic

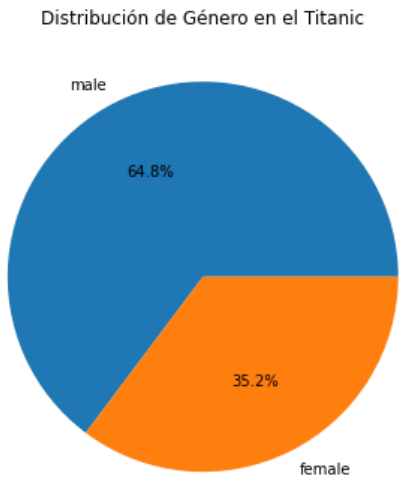

Se puede continuar explorando y visualizando más aspectos de los datos, como la correlación entre variables, la distribución de tarifas, etc., según los objetivos de análisis. La biblioteca ***seaborn*** es especialmente útil para la creación de gráficos informativos y visualmente atractivos.

Se va a calcular la matriz de correlación y luego visualizarla de manera efectiva, utilizando la biblioteca *panda* para manejar los datos y seaborn para la visualización.

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

# Cargar el conjunto de datos del Titanic
titanic_df = pd.read_csv('titanic.csv')
# Seleccionar las variables numéricas principales para el análisis de correlación
variables_numericas = ['Age', 'SibSp', 'Parch', 'Fare']
```

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

```
# Crear una submatriz de correlación
correlation_matrix = titanic_df[variables_numericas].corr()

# Crear un mapa de calor de correlación
plt.figure(figsize=(10, 8))
sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm', linewidths=.5)
plt.title('Matriz de Correlación entre Variables Numéricas del Titanic')
plt.show()
```

En este código:

- Se carga el conjunto de datos del Titanic en un DataFrame de pandas.
- Se selecciona las variables numéricas que se desea incluir en el análisis de correlación, en este caso, 'Age' (edad), 'SibSp' (número de hermanos/cónyuges a bordo), 'Parch' (número de padres/hijos a bordo) y 'Fare' (tarifa).
- Se calcula la matriz de correlación utilizando el método .corr() del DataFrame.
- Se visualiza la matriz de correlación en un mapa de calor usando seaborn. Los valores de correlación se muestran en cada celda del mapa de calor (Figura 10).

Figura 10. Matriz de correlación entre las variables numéricas del dataset Titanic

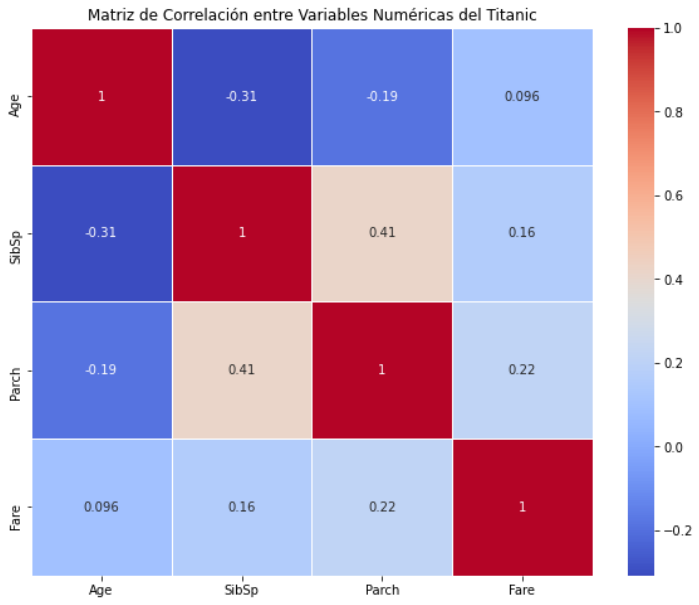

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

El mapa de calor de correlación muestra la fuerza y la dirección de las correlaciones entre estas variables numéricas. Los valores de correlación pueden variar entre -1 y 1, donde -1 indica una correlación negativa perfecta, 1 indica una correlación positiva perfecta y 0 indica que no hay correlación. Además, los colores del mapa de calor ayudan a identificar visualmente las relaciones. Para dar un mayor significado a la correlación se puede utilizar los valores de la Tabla 4.

Tabla 4. Significado de la correlación

VALOR	SIGNIFICADO
-1	Correlación negativa grande y perfecta
-0,9 a -0,99	Correlación negativa muy alta
-0,7 a -0,89	Correlación negativa alta
-0,4 a -0,69	Correlación negativa moderada
-0,2 a -0,39	Correlación negativa baja
-0,01 a -0,19	Correlación negativa muy baja
0	Correlación nula
0,01 a 0,19	Correlación positiva muy baja
0,2 a 0,39	Correlación positiva baja
0,4 a 0,69	Correlación positiva moderada
0,7 a 0,89	Correlación positiva alta
0,9 a 0,99	Correlación positiva muy alta
1	Correlación positiva grande y perfecta

Fuente: Lind et al. (2015)

Este análisis de correlación permitirá entender mejor cómo las variables numéricas principales se relacionan entre sí en el conjunto de datos del Titanic y puede ser útil para futuros análisis o modelado de datos.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Conclusiones

En esta unidad se ha revisado los fundamentos de la ciencia de datos, respecto al Análisis exploratorio de datos (estadísticas y visualización) que es una parte fundamental de cualquier proyecto de análisis de datos que tiene varios propósitos importantes, tales como: Comprender los datos, incluyendo la estructura de los datos, sus características, distribuciones, tendencias y patrones subyacentes; Detectar Anomalías y Errores; Seleccionar variables relevantes; Generar hipótesis iniciales sobre relaciones entre variables; Tomar decisiones iniciales sobre cómo abordar el proyecto de análisis de datos (elección de algoritmos), Optimización de recursos eliminando variables irrelevantes o reducir la dimensionalidad de los datos; Preparación para un modelado avanzado de datos, etc. Se motiva a los estudiantes a revisar material y ejemplos adicionales disponibles libremente en Internet.

ANEXOS

Referencias:

Lind et al., (2015). Estadística aplicada a los negocios y la economía. 16° ed. McGraw-Hill: México.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Autor: Iván García Santillán

El preprocesamiento de datos

Introducción

El procesamiento de datos implica la preparación de los datos crudos para su posterior análisis utilizando algoritmos de aprendizaje automático. En general, algunas de las tareas comunes de preprocesamiento de datos incluyen:

- Limpieza de datos para tratar valores faltantes (nulos), valores atípicos y datos inconsistentes.
- Escalado o normalización de datos numéricos.
- Transformación (codificación) de datos categóricos en un formato adecuado para su análisis.
- Reducción de la dimensionalidad si fuese necesario.

A continuación, se detallan las tareas mencionadas utilizando ejercicios prácticos con el lenguaje Python (InteractiveChaos, 2023).

Contenido

Tareas en la preparación de los datos:

Escalado o normalización de datos numéricos:

Antes de entrenar un algoritmo con nuestros datos de entrenamiento debemos asegurarnos de que éstos se encuentran en la forma adecuada.

Algunos algoritmos (como RNA, SVM, K-NN, Logistic regression, ...) son muy sensibles a la escala de los datos (cm, m, km, miles, millones, etc.) (a diferencia de Decision Tree, random forests que son más robustos en este sentido), tendiendo a dar mayor o menor importancia a aquellas características que tomen valores mayores, ver Figura 6. Desde este punto de vista, representar una

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

distancia en kilómetros o en metros no va a modificar el concepto representado (distancia), pero puede tener un impacto indeseable en el comportamiento de ciertos algoritmos. Por lo que resulta conveniente transformarlos de forma que todas las características (predictoras) tenga una escala semejante.

Figura 6 Normalización de datos

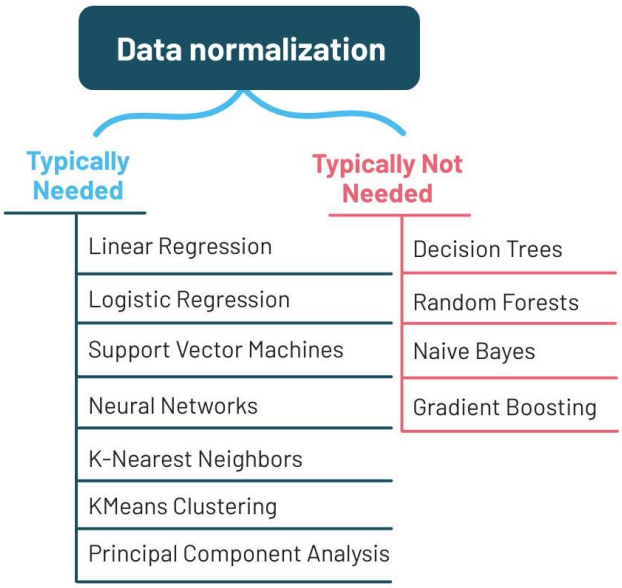

Fuente: InteractiveChaos (2023)

Para aplicar un escalado semejante a las diferentes características (variables predictoras, no es necesario escalar la variable objetivo) tenemos dos enfoques diferentes: el escalado y la normalización.

El **escalado** va a transformar los valores de las características de forma que estén confinados en un rango [a, b], típicamente [0, 1] o [-1, 1].

La **normalización** va a transformar las características de forma que todas compartan un mismo valor medio (u=0) y una misma desviación estándar (σ=1). Las variables categóricas no son susceptibles de aplicar normalización.

En python, Scikit-Learn library ofrece diferentes escaladores: *Standard Scaler* (u=0, σ=1), *MinMaxScaler* (rango [a, b]).
from sklearn.preprocessing import ***StandardScaler***
from sklearn.preprocessing import ***MinMaxScaler***

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Gestión de valores nulos:

La posible existencia de valores nulos en nuestro conjunto de datos es un problema que también deberemos solucionar (imputación de datos).

Veamos algunas técnicas para resolver este problema:

- **Eliminación de muestras o de características (x):** Este método puede ser aplicable solo si el tamaño de los datos es suficientemente grande. De otra forma podemos estar perdiendo demasiada información. Aquí podemos verificar el % de nulos que hay en cada variable (< 10% de nulos podría ser aceptable).

- **Reemplazo por la media, mediana o moda (imputación de datos):** Es aplicable solo cuando la característica es numérica (la moda también es aplicable a características categóricas). Una versión más sofisticada es el reemplazo de aquellos valores de la característica que pertenecen a un determinado grupo. Debemos ser conscientes, en todo caso, que estamos añadiendo información al modelo que puede añadir sesgo o varianza a los datos. En Python, *Scikit-Learn library* ofrece la clase:
  sklearn.impute.SimpleImputer

- **Asignación a una categoría exclusiva:** Si estamos trabajando con una variable categórica, podemos crear una categoría nueva (ej. unknow) y asignarla a todos los valores nulos.

- **Predicción de los valores nulos:** usando alguna técnica de predicción como p. ej. regresión lineal o múltiple. Un problema que puede surgir es que los valores imputados pertenezcan a un rango que no pueda darse en la realidad (edad o sueldo con valores negativos).
  from sklearn.linear_model import LinearRegression

Gestión de características categóricas:

Ya se ha comentado que los algoritmos generalmente necesitan valores numéricos para poder ser entrenados, lo que nos obliga a codificar adecuadamente los posibles valores categóricos que existan en nuestro conjunto de datos.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Frecuentemente nos encontramos con *datasets* que incluyen características **categóricas** (nominal), normalmente almacenadas con formato de texto (género, estado civil, ciudad, país, …). Generalmente, los algoritmos de aprendizaje automático y las redes neuronales de aprendizaje profundo (*Deep Learning*) requieren que las variables de entrada y salida sean números…

Aunque hay ciertos algoritmos (como *decision tree*) capaces de trabajar con variables de tipo texto, la mayor parte exigen valores numéricos, por lo que la pregunta que debemos hacernos es ¿cómo convertir estos valores en números? Esto significa que los datos categóricos deben codificarse en números antes de que podamos usarlos para ajustar y evaluar un modelo.

Como suele ocurrir en el área de *Data Science*, la respuesta no es única. Cada enfoque tiene sus ventajas e inconvenientes, y será el entorno (nuestros datos, problema, modelo) el que nos lleve en cada caso a decantarnos por una u otra opción. Revisemos los dos enfoques más frecuentemente usados: **Label Encoding** y **One-Hot Encoding**. El uso de algún enfoque tiene un gran impacto en la precisión de la predicción.

Label Encoding:

En este enfoque cada etiqueta única se asigna a un número entero. Identificar los distintos valores existentes (etiquetas/clases) y sustituir cada uno de ellos por un número (0, 1, 2, …. N-1). De esta forma, podríamos sustituir "male" por el valor 0 y "female" por el valor 1, por ejemplo.

El método de *Label Encoding* tiene la ventaja de ser sencillo de implementar. Sin embargo, tiene un cierto problema: los valores numéricos pueden ser malinterpretados por algunos algoritmos (como RNA): si hemos codificado varias ciudades con los valores 0, 1, 2 y 3 ¿significa que la ciudad correspondiente al valor 3 (digamos Ecuador) es el triple (o mayor) que la que ha recibido el valor 1 (digamos Colombia).

from sklearn.preprocessing import LabelEncoder

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

One-Hot Encoding (OHE):

One-Hot Encoding es el proceso de creación de variables ficticias donde cada etiqueta se asigna a un vector binario. La estrategia que implementa es crear una columna para cada valor distinto que exista en la característica que estamos codificando y, para cada registro, marcar con un 1 la columna a la que pertenezca dicho registro y dejar las demás con 0 (Tabla 2).

Tabla 2. One-Hot encoding sobre la variable género

gender	
gender_male	gender_female
1	0
0	1

Scikit-Learn implementa esta funcionalidad en la clase: sklearn.preprocessing.OneHotEncoder

Aplicamos codificación One-Hot cuando:

- La característica categórica (X) es nominal al igual que los países (donde no existe relación entre categorías).
- La cantidad de características categóricas es menor, por lo que la codificación one-hot se puede aplicar de manera efectiva.

Aplicamos codificación Label-Encoding cuando:

- El rasgo categórico es ordinal como Likert.
- El número de categorías es bastante grande, ya que la codificación one-hot puede provocar un alto consumo de memoria.

Taller:

Realice el preprocesamiento de datos en el dataset "Titanic" dado por la librería *seaborn que contiene 15 columnas y 891 registros* (Tabla 3):

import seaborn as sns

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

titanic = sns.load_dataset("titanic")
titanic.head()

Tabla 3. Variables del dataset Titanic

	survived	pclass	sex	age	sibsp	parch	fare	embarked	class	who	adult_male	deck	embark_town	alive	alone
0	0	3	male	22.0	1	0	7.2500	S	Third	man	True	NaN	Southampton	no	False
1	1	1	female	38.0	1	0	71.2833	C	First	woman	False	C	Cherbourg	yes	False
2	1	3	female	26.0	0	0	7.9250	S	Third	woman	False	NaN	Southampton	yes	True
3	1	1	female	35.0	1	0	53.1000	S	First	woman	False	C	Southampton	yes	False
4	0	3	male	35.0	0	0	8.0500	S	Third	man	True	NaN	Southampton	no	True

A continuación, se presenta un código básico de Python con la explicación (comentarios) respectiva (adaptado de Gonzalez, 2023):

```
########## librerías a utilizar ##########

#Se importan las librerías a utilizar
import numpy as np
import pandas as pd

########## Importando la data ##########

#Importar los datos de los archivos .csv almacenados
df_test = pd.read_csv('titanic_test.csv')
df_train = pd.read_csv('titanic_train.csv')

print(df_test.head())
print(df_train.head())

########## Entendimiento de la data ##########

#Verifica la cantidad de datos que hay en los dataset
print('Cantidad de datos:')
print(df_train.shape)
print(df_test.shape)

#Verifica el tipo de datos contenida en ambos dataset
```

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

```
print('Tipos de datos:')
print(df_train.info())
print(df_test.info())

#Verifica los datos faltantes de los dataset
print('Datos faltantes:')
print(pd.isnull(df_train).sum())
print(pd.isnull(df_test).sum())

#Verifica las estadísticas básicas del dataset
print('Estadísticas del dataset:')
print(df_train.describe())
print(df_test.describe())

########## Preprocesamiento de la data ##########

# Transforma los datos de la variable sexo (categórico) en números
df_train['Sex'].replace(['female','male'],[0,1],inplace=True)
df_test['Sex'].replace(['female','male'],[0,1],inplace=True)

#Transforma los datos de embarque (categórico) en números
df_train['Embarked'].replace(['Q','S', 'C'],[0,1,2],inplace=True)
df_test['Embarked'].replace(['Q','S', 'C'],[0,1,2],inplace=True)

#Reemplazo los datos faltantes en la edad por la media de esta variable
print(df_train["Age"].mean())
print(df_test["Age"].mean())
promedio = 30
df_train['Age'] = df_train['Age'].replace(np.nan, promedio)
df_test['Age'] = df_test['Age'].replace(np.nan, promedio)

#Crea varios grupos/rangos de edades
#Rangos: 0-8, 9-15, 16-18, 19-25, 26-40, 41-60, 61-100
bins = [0, 8, 15, 18, 25, 40, 60, 100]
names = ['1', '2', '3', '4', '5', '6', '7']
df_train['Age'] = pd.cut(df_train['Age'], bins, labels = names)
df_test['Age'] = pd.cut(df_test['Age'], bins, labels = names)
```

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

```
#Se elimina la columna de "Cabin" ya que tiene muchos datos perdidos
df_train.drop(['Cabin'], axis = 1, inplace=True)
df_test.drop(['Cabin'], axis = 1, inplace=True)

#Elimina las columnas que se considera que no son necesarias para el analisis
df_train = df_train.drop(['PassengerId','Name','Ticket'], axis=1)
df_test = df_test.drop(['Name','Ticket'], axis=1)

#Se elimina las filas con datos perdidos
df_train.dropna(axis=0, how='any', inplace=True)
df_test.dropna(axis=0, how='any', inplace=True)

#Verifica los datos
print(pd.isnull(df_train).sum())
print(pd.isnull(df_test).sum())

print(df_train.shape)
print(df_test.shape)

print(df_test.head())
print(df_train.head())
```

Trabajo autónomo: Este ejemplo nos ayuda a comprender el impacto de Label y One-Hot encoder en un modelo para un problema de clasificación binaria usando una MLP (multi-layer perceptron) y el dataset Breast-cancer que contiene 30 columnas (clic aquí) https://machinelearningmastery.com/how-to-prepare-categorical-data-for-deep-learning-in-python/

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Conclusiones

En esta lectura se han revisado los fundamentos de la ciencia de datos, respecto al preprocesamiento de datos. Antes de realizar el análisis de los datos, es necesario realizar un preprocesamiento de los datos. Este paso implica principalmente la limpieza de datos, Escalado o normalización de datos numéricos y Transformación (codificación) de datos categóricos en un formato adecuado para su análisis a través de algoritmos de aprendizaje automático como los que se verán más adelante. Se motiva a los estudiantes a revisar material y ejemplos adicionales disponibles libremente en Internet.

ANEXOS

Referencias:

Gonzalez, L. (2023). Predecir la supervivencia del Titanic. http://ligdigonzalez.com/predecir-la-supervivencia-del-titanic-utilizando-python/

InteractiveChaos. (2023). Preprocesamiento de datos. https://interactivechaos.com/en/node/916

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Autor:
Iván García Santillán

Fundamentos de la ciencia de datos

Introducción

En esta unidad se revisa los conceptos teóricos relevantes inmersos en el mundo de la ciencia de datos, su importancia para las personas, empresas y sociedad, las metodologías para el desarrollo de proyectos de análisis de datos, los roles existentes y las habilidades blandas necesarias, así como los aspectos éticos en el uso del big data. Además, se realiza el preprocesamiento de los datos y un análisis exploratorio de datos (estadísticas y visualización).

Palabras clave

Fundamentos, metodologías, roles, aspectos éticos, preprocesamiento de datos, análisis exploratorio de datos.

Reto

¿Cuáles son las fases y actividades que se deben desarrollar durante un proyecto de análisis de datos?

Desarrollo

1. Fundamentos del Data Science

1.1. Definición e importancia de la ciencia de datos y Big Data

El Big Data es el análisis masivo de datos. Una cuantía de datos, sumamente grande, que las aplicaciones de software de procesamiento

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

de datos que tradicionalmente se venían usando no son capaces de capturar, tratar y poner en valor en un tiempo razonable; También se refiere a los procedimientos usados para encontrar patrones/relaciones repetitivos dentro de esos datos (Wikipedia, 2023).

Las dificultades más habituales vinculadas a la gestión de estas cantidades de datos se centran en la recolección y el almacenamiento, búsqueda, compartición, análisis, y visualización.

La tendencia a manipular enormes cantidades de datos se debe a su crecimiento de manera exponencial provenientes de varias fuentes: Internet (buscadores, correo), IoT, dispositivos móviles, redes sociales, comercio electrónico, etc.

Tipos de datos en big data (Hoang, 2016):

- **Datos estructurados (Structured Data):** Datos que tienen bien definidos su longitud y su formato, como las fechas, los números o las cadenas de caracteres. Se almacenan en tablas. Un ejemplo son las bases de datos relacionales y las hojas de cálculo.

- **Datos no estructurados (Unstructured Data):** Datos en el formato tal y como fueron recolectados, que carecen de un formato específico. No se pueden almacenar dentro de una tabla ya que no se puede desgranar su información a tipos básicos de datos. Algunos ejemplos son los PDF, documentos multimedia (imagen, audio, video), e-mails o documentos de texto.

- **Datos semiestructurados (Semistructured Data):** Siguen una especie de estructura, pero no es lo suficiente regular como para gestionarla como datos estructurados, Ej. HTML, XML, Json.

Características del Big Data: las 7 "V":

- **Velocidad:** con la que actualmente se generan y procesan los datos.
- **Volumen:** la cantidad de datos generados está aumentando exponencialmente.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

- **Variedad:** proceden de numerosas fuentes y se encuentran en distintos formatos, cada vez más en forma no estructurada.
- **Veracidad:** fiabilidad y calidad de los datos (ISO/IEC 25012)
- **Valor:** El valor de los datos está en que sean accionables, es decir, que permitan tomar una decisión/acción (la mejor) en base a los datos. Hace referencia al beneficio para las empresas.
- **Visualización:** mostrar gráficamente los resultados de forma clara, sencilla. Resumida (dashboard, balacescorecard).
- **Variabilidad:** varían mucho, no son fijos en el tiempo y requieren de un control periódico. Ej. modelos post-covid

Beneficios del Big Data:

- Convertir: Dato □ información □ conocimiento □ decisión □ acción
- Permite que una empresa tenga ventajas competitivas.
- Transformación digital basada en datos.
- Podremos sacar conclusiones con una base más sólida y unos conceptos que se orienten a la toma de decisiones/acciones efectivas.
- Todo ello, aplicando no únicamente variables del pasado, sino predicciones a futuro mucho más fundamentadas en una base científica.
- Casos de éxito empresarial: Amazon: recomendación de productos; Netflix: creación de nuevos contenidos basado en preferencias; T-Mobile: retención de clientes. Nike: Fidelización de clientes (promociones, desafíos).
- Otros ámbitos de aplicación: selección de deportistas para clubes de élite (Manchester United), ayuda en campaña electoral (Facebook), detección de fraudes bancarios, sistemas de detección de intrusos IDS, etc.

¿Por qué dominar Big Data?

- Tres razones (Udemy, 2023):

    a) Actualmente, el Big Data es el principal destino para la inversión para las empresas.
    b) Es la principal fuente de empleo cualificado.
    c) Es la mayor causa de creación de empresas de productos y servicios (*startups*) en el ámbito de los sistemas de información.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

- Los profesionales dedicados al tratamiento del Big Data, denominados *Data Scientists*, se han convertido en unos de los mejores pagados del sector TIC, en parte por la escasez de profesionales con este perfil.

- Según la encuesta anual *KDNuggets*, el salario de un *Data Scientist* en Estados Unidos oscila entre los 103.000 y los 131.000 dólares mientras que en Europa se encuentra entre los 54.000 y los 82.000 dólares.

Ciencia de Datos:

La ciencia de datos es un campo interdisciplinario que utiliza estadística, computación científica, métodos, procesos, algoritmos y sistemas para obtener (recolectar o extraer), tratar, analizar y presentar informes a partir de datos ruidosos, estructurados y no estructurados (Wikipedia, 2023b).

La parte medular de la ciencia de datos son los algoritmos de Inteligencia Artificial que manejan datos, ellos forman parte de la minería de datos, y tienen la finalidad de explorar y sacarles el máximo valor. Dentro de este campo, tenemos 2 tipos de aprendizaje: El supervisado y no supervisado. La principal diferencia entre el aprendizaje supervisado y el aprendizaje no supervisado radica en la disponibilidad de etiquetas en los datos de entrenamiento. En el aprendizaje supervisado, el modelo se entrena utilizando datos etiquetados con el objetivo de hacer predicciones precisas, mientras que, en el aprendizaje no supervisado, el modelo busca estructuras o patrones en los datos sin la guía de etiquetas. Ambos enfoques son esenciales en el aprendizaje automático y se utilizan en una variedad de aplicaciones.

Además, en la Figura 1 se muestra la relación de la ciencia de datos con la inteligencia de negocios que combina análisis de negocios, minería de datos, visualización de datos, herramientas e infraestructura de datos, y las prácticas recomendadas para ayudar a las organizaciones a tomar decisiones más basadas en los datos.

Figura 1 Ciencia de datos y su relación con la inteligencia de negocios

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Fuente: Bantu (2021)

Principalmente, la inteligencia de negocios trabaja con los datos históricos preparados, generados y almacenados por las empresas. La ciencia de datos se enfoca en el futuro, responde preguntas tales como, ¿qué pasaría si se hace tal o cual cosa?, e identifica patrones o tendencias para crear predicciones (Bantu, 2021).

Minería de Datos (Data Mining)

La minería de datos o exploración de datos (es la etapa de análisis de "*Knowledge Discovery in Databases*" o KDD) es un campo de la estadística y las ciencias de la computación referido al proceso que intenta descubrir patrones (relaciones, tendencias) en grandes volúmenes de conjuntos de datos (Lara, 2014).

Utiliza los métodos de la inteligencia artificial, aprendizaje automático, estadística y sistemas de bases de datos.

Tenemos 2 grandes grupos: técnicas predictivas y descriptivas.

Técnicas y algoritmos de análisis de datos masivos:

- **Técnicas predictivas:**

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

- **Clasificación:** El atributo a predecir (target) es de tipo cualitativo (categoría). Ej. clasificación de objetos en imágenes: perro, gato, avión, laptop. Algoritmos clásicos: RNA (MLP), SVM, decision tree, K-NN, Naive Bayes, logistic regression, Random Forest (ensemble).

- **Regresión:** similar a la clasificación, pero el atributo a predecir es de tipo cuantitativo. Regresión lineal y múltiple. Algoritmos: linear and multiple regression with least-squares method.

  Nota: la regresión *logística* es una técnica utilizada para clasificación.

- **Técnicas Descriptivas:**

  - **Agrupamiento:** segmentación en grupos homogéneos. Ej. Clientes tipo A, B, C. Algoritmos: : k-means, Expectation Maximization (EM).

  - **Asociación:** identificación de productos que habitualmente se compran juntos (análisis de la canasta). Ej. pan, azúcar leche. Reglas antecedente-consecuente. Algoritmos: A priori, FP Growth

  - **Detección de atípicos:** localización de objetos que manifiestan características significativamente diferentes al resto y afectan a los modelos. Técnicas estadísticas: scatter-plot, box-plot y Algoritmos: Isolation Forest, Minimum Covariance Determinant, Local Outlier Factor, One-Class SVM.

1.2. Metodologías para desarrollo de proyectos de análisis de datos

Una **metodología** no solo define las **fases** de un proceso, sino también las **tareas** que deberían realizarse y **cómo** llevar a cabo las mismas. Algunas metodologías muy utilizadas para el análisis de datos son:

- KDD (knowledge Discovery in databases, 1996)
- CRISP-DM (Cross-Industry Standard Process for Data Mining, 2000)

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

KDD constituyó el primer modelo aceptado en la comunidad científica que estableció las etapas principales de un proyecto de explotación de información. Está más cercano a un modelo de proceso, ya que sólo proponen las fases generales para el proceso de minería de datos y no incorpora actividades para la gestión del proyecto (como la gestión del tiempo, costo, riesgo). En la Figura 2 se muestra el proceso KDD.

Figura 2 Metodología KDD para de análisis de datos

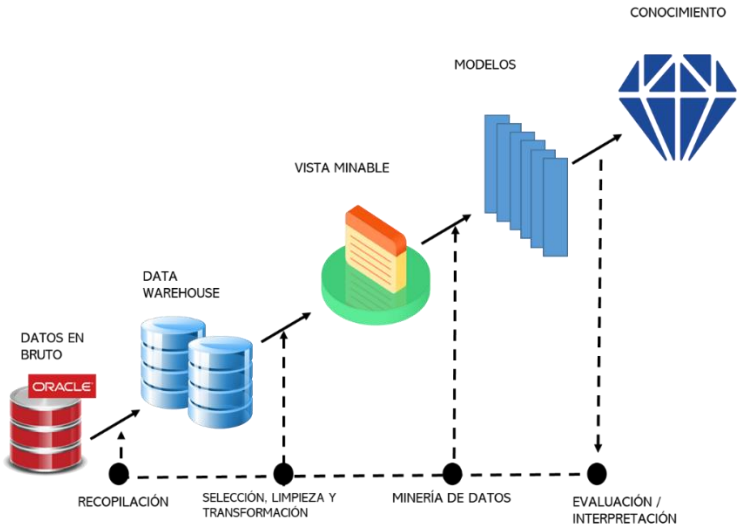

Fuente: Fayyad, U. (1996).

CRISP-DM podrían ser considerados una metodología, por el nivel de detalle con el que describen las tareas en cada fase del proceso, y porque incorporan actividades para la gestión del proyecto. CRISP-DM es actualmente la guía de referencia más utilizada en el desarrollo de proyectos de minería de datos.

Figura 3. Metodología CRISP-DM para de análisis de datos

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

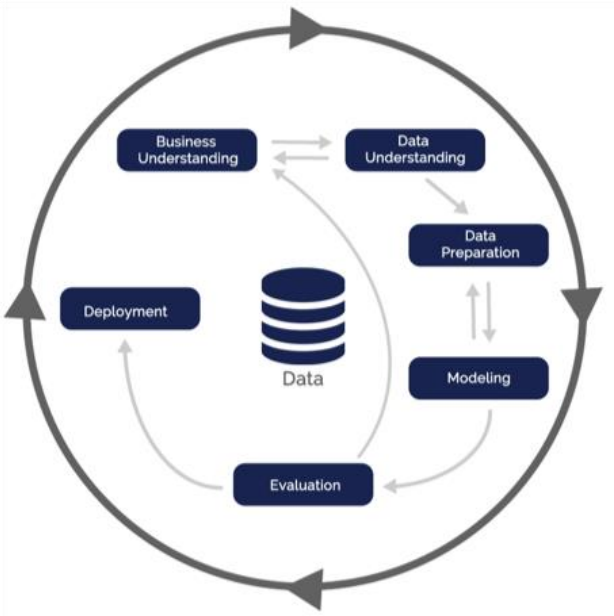

Fuente: Chapman et al. (2000)

Las fases del proceso de análisis de datos en cada modelo se muestran en la Tabla 1.

Tabla 1. Fases de las metodologías de análisis de datos

Fases	KDD	CRISP – DM
Análisis y comprensión del negocio	Comprensión del dominio de aplicación	Comprensión del negocio
Selección y preparación de los datos	Crear el conjunto de datos Limpieza y pre-procesamiento de los datos Reducción y proyección de los datos	Entendimiento de los datos Preparación de los datos
Modelado	Determinar la tarea de minería Determinar el algoritmo de minería Minería de datos	Modelado
Evaluación	Interpretación	Evaluación
Implementación	Utilización del nuevo conocimiento	Despliegue

Fuente: Moine et al. (2011)

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

1.3. Roles y habilidades blandas para ciencia de datos

Los roles identificados en ciencia de datos son: Ingeniero de datos, Científico de datos y Desarrollador de aplicaciones analíticas como se muestra en la Figura 4.

Figura 4. Roles identificados en la ciencia de datos

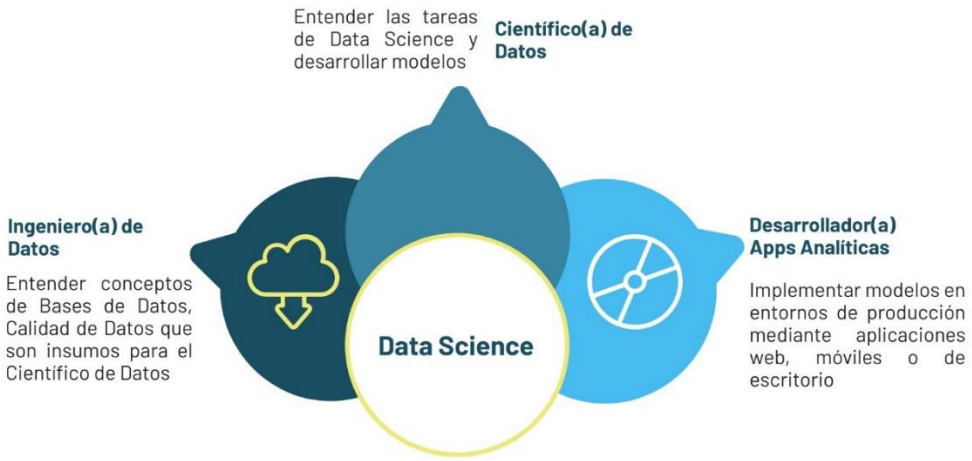

Fuente: SEE (2023)

En la Figura 5 se muestran las habilidades blandas requeridas para ciencia de datos.

Figura 5. Habilidades blandas para ciencia de datos

Fuente: Data Solutions (2022)

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

1.4. Aspectos legales y éticos del uso del Big Data.

La privacidad y la seguridad son cuestiones críticas en el mundo de la tecnología y los datos. **La privacidad** se refiere a la protección de la información personal y sensible de las personas. En el contexto del Big Data, existen preocupaciones legales y éticas relacionadas con la recopilación, el almacenamiento y el uso de datos personales. **La seguridad** de los datos en el contexto del Big Data se refiere a la protección contra amenazas cibernéticas y la garantía de que los datos se almacenan y transmiten de manera segura.

El uso del Big Data plantea desafíos legales y éticos importantes en relación con la privacidad y la seguridad de los datos. Las organizaciones que trabajan con Big Data deben ser conscientes de estas preocupaciones y tomar medidas adecuadas para proteger la privacidad de las personas y garantizar la seguridad de los datos. Además, deben estar al tanto de las regulaciones y leyes específicas en sus regiones y cumplir con ellas de manera rigurosa para evitar consecuencias legales y daños a su reputación.

Algunas normativas que se deben considerar en Ecuador y la región son las siguientes:

- Ley orgánica de protección de datos personales (LOPDP, mayo 2021.
- Recomendación sobre la Ética de la Inteligencia Artificial (Unesco, Nov. 2021).

El objeto y finalidad de la **ley LOPDP** (2021) es garantizar el ejercicio del derecho a la protección de datos personales, que incluye el acceso y decisión sobre información y datos de este carácter, así como su correspondiente protección, Para dicho efecto regula, prevé y desarrolla principios, derechos, obligaciones y mecanismos de tutela.

La **Recomendación sobre la ética de la inteligencia artificial** es el primer instrumento normativo mundial sobre la ética de la inteligencia artificial propuesto por la Unesco (2021). La ética en la inteligencia artificial se refiere al estudio de los valores y principios éticos que deben guiar la creación y uso de sistemas de inteligencia artificial. Esto incluye la toma de decisiones, la transparencia y la responsabilidad en el desarrollo y uso de la tecnología.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Trabajo autónomo:

Realice un cuadro sinóptico o mapa mental o infografía respecto a la ética, Privacidad y Seguridad de los datos considerando las dos normativas mencionadas y suba a la plataforma.

1.5. Preprocesamiento de datos

Este paso implica la preparación de los datos crudos para su posterior análisis. En general, algunas de las tareas comunes de preprocesamiento de datos incluyen:

- Limpieza de datos para tratar valores faltantes (nulos), valores atípicos y datos inconsistentes.
- Escalado o normalización de datos numéricos.
- Transformación (codificación) de datos categóricos en un formato adecuado para su análisis.
- Reducción de la dimensionalidad si fuese necesario.

En la lectura de profundización se abordará cada una de estas actividades a detalle (InteractiveChaos, 2023).

1.6. Análisis exploratorio de datos (estadísticas y visualización)

El análisis exploratorio de datos (EDA por sus siglas en inglés, Exploratory Data Analysis) es una parte fundamental de cualquier proyecto de análisis de datos que tiene varios propósitos importantes, tales como: Comprender los datos, incluyendo la estructura de los datos, sus características, distribuciones, tendencias y patrones subyacentes); Detectar Anomalías y Errores; Seleccionar variables relevantes; Generar hipótesis iniciales sobre relaciones entre variables; Tomar decisiones iniciales sobre cómo abordar el proyecto de análisis de datos (elección de algoritmos), Optimización de recursos eliminando variables irrelevantes o reducir la dimensionalidad de los datos; Preparación para un modelado avanzado, etc.

Aquí se mostrará cómo realizar un análisis exploratorio de datos básico en el conjunto de datos del *Titanic* utilizando Python, centrándonos en estadísticas descriptivas y visualización de datos. Estas actividades se abordarán a detalle en la lectura de profundización.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Conclusiones

En esta unidad se ha revisado los fundamentos de la ciencia de datos, tales como:

- Definición e importancia de la ciencia de datos y Big Data
- Metodologías para desarrollo de proyectos de análisis de datos
- Roles y habilidades blandas para ciencia de datos
- Aspectos legales y éticos del uso del Big Data
- Preprocesamiento de datos
- Análisis exploratorio de datos (estadísticas y visualización)

La ciencia de datos es una disciplina interdisciplinaria que utiliza estadística, computación científica, métodos, procesos, algoritmos y sistemas para obtener (recolectar o extraer), tratar, analizar y presentar informes a partir de datos ruidosos, estructurados y no estructurados. La parte medular de la ciencia de datos son los algoritmos de Inteligencia Artificial que manejan datos, y tienen la finalidad de explorar y sacarles el máximo valor. Dentro de este campo, tenemos 2 tipos de aprendizaje: El supervisado y no supervisado. La principal diferencia entre el aprendizaje supervisado y el aprendizaje no supervisado radica en la disponibilidad de etiquetas en los datos de entrenamiento. En el aprendizaje supervisado, el modelo se entrena utilizando datos etiquetados con el objetivo de hacer predicciones precisas, mientras que en el aprendizaje no supervisado, el modelo busca estructuras o patrones en los datos sin la guía de etiquetas. Ambos enfoques son esenciales en el aprendizaje automático y se utilizan en una variedad de aplicaciones.

Para el desarrollo de proyectos de análisis de datos se requiere seguir una metodología la cual no solo define las fases de un proceso, sino también las tareas que deberían realizarse y cómo llevar a cabo las mismas. Algunas metodologías muy utilizadas para el análisis de datos son: KDD y CRISP-DM.

También, la privacidad y la seguridad son cuestiones críticas en el mundo de la tecnología y los datos. La privacidad se refiere a la protección de la información personal y sensible de las personas y la seguridad de los datos se refiere a la protección contra amenazas cibernéticas. Para ello hay que considerar la normativa existente en el país y la región, tales como: Ley

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

orgánica de protección de datos personales (Asamblea Nacional) y las recomendaciones sobre la Ética de la Inteligencia Artificial (Unesco).

Por otro lado, antes de realizar el análisis de los datos, es necesario realizar un preprocesamiento de los datos. Este paso implica principalmente la limpieza de datos, Escalado o normalización de datos numéricos y Transformación (codificación) de datos categóricos en un formato adecuado para su análisis.

Así mismo, el análisis exploratorio de datos es una parte fundamental de cualquier proyecto de análisis de datos que tiene varios propósitos importantes, tales como: Comprender los datos, incluyendo la estructura de los datos, sus características, distribuciones, tendencias y patrones subyacentes; Detectar Anomalías y Errores; Seleccionar variables relevantes; Generar hipótesis iniciales sobre relaciones entre variables; Tomar decisiones iniciales sobre cómo abordar el proyecto de análisis de datos (elección de algoritmos), Optimización de recursos eliminando variables irrelevantes o reducir la dimensionalidad de los datos; Preparación para un modelado avanzado de datos, etc.

Bibliografía:

Asamblea Nacional del Ecuador. (2021). Ley Orgánica de Protección de Datos Personales de Ecuador (LOPDP). Ecuador.

Bantu. (2021). Ciencia de datos e Inteligencia de Negocios, características y diferencias. https://www.bantugroup.com/blog/ciencia-de-datos-e-inteligencia-de-negocios

Brownlee, J. (2023). Machine Learning Mastery. https://machinelearningmastery.com

Chapman, P. et al. (2000). CRISP-DM 1.0: Step-by-step data mining guide. https://api.semanticscholar.org/CorpusID:59777418

Data Solutions. (2022). Habilidades blandas para ciencia de datos.

Fayyad, U. (1996). Advances in Knowledge Discovery and Data Mining. MIT Press.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

García-Santillán, I. (2023). Ciencia y analítica de datos. Maestría en Inteligencia Artificial aplicada. Universidad Hemisferios.

Gonzalez, L. (2023). Predecir la supervivencia del Titanic. http://ligdigonzalez.com/predecir-la-supervivencia-del-titanic-utilizando-python/

Hoang, A. (2016). Tipos de datos en Big Data. https://anhngohoang.wordpress.com/2016/05/

InteractiveChaos. (2023). Preprocesamiento de datos. https://interactivechaos.com/en/node/916

Lara, J. (2014). Minería de Datos. Madrid: CEF-Udima.

Lind et al., (2015). Estadística aplicada a los negocios y la economía. 16° ed. McGraw-Hill: México.

Moine, J. (2011). Análisis comparativo de metodologías para la gestión de proyectos de minería de datos. CACIC 2011 - XVII Congreso argentino de ciencias de la computación. https://core.ac.uk/download/pdf/15775611.pdf

SEE. (2023). Roles en un proyecto de ciencia de datos. Sociedad Ecuatoriana de Estadística en Facebook. https://www.facebook.com/socecuest

Unesco. (2021). Recomendación sobre la ética de la inteligencia artificial. https://unesdoc.unesco.org/ark:/48223/pf0000380455_spa

Udemy (2023). Análisis de Big Data. https://www.udemy.com/course/analisis-de-big-data/

Wikipedia. (2023a). Big Data. https://es.wikipedia.org/wiki/Macrodatos

Wikipedia. (2023b). Ciencia de Datos. https://es.wikipedia.org/wiki?curid=7036548

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Ciencia de Datos

- Procesamiento de datos
- Análisis exploratorio de datos
- Metodologías: KDD, Crisp-DM
- Aspectos éticos y legales
- Roles y habilidades blandas
- Herramientas: Colab, Spyder, VS Code
- Frameworks y librerías