Autor:
Iván García Santillán

Herramientas y conjunto de datos para Ciencia de Datos

Introducción

En esta unidad se utiliza herramientas y conjuntos de datos públicos para el entrenamiento de algunos algoritmos de aprendizaje automático supervisado (clasificación) siguiendo una metodología para el desarrollo de proyectos de análisis de datos y los aspectos éticos en el uso y aprovechamiento del Big Data. Los algoritmos de clasificación que abordaremos aquí son regresión logística, y vecinos más cercanos (K-NN) para problemas de clasificación binaria y/o multi-clasificación, todos ellos utilizando el lenguaje Python y el framework TensorFlow-Keras.

Palabras clave

Herramientas para Data Science, metodologías, datasets, aprendizaje automático.

Reto

¿Qué herramientas y algoritmos resultan más adecuados para abordar un problema de clasificación binario/multiclase?

Desarrollo

2. Herramientas para ciencia de datos

2.1. Introducción al aprendizaje supervisado y no supervisado

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

El aprendizaje supervisado y no supervisado son dos enfoques fundamentales en el campo del aprendizaje automático.

En el **aprendizaje supervisado**, se utilizan datos de entrenamiento que están etiquetados, lo que significa que cada ejemplo en el conjunto de datos tiene una etiqueta o respuesta conocida. El aprendizaje supervisado se utiliza típicamente para desarrollar modelos predictivos. Esto incluye modelos de clasificación (como predecir si un correo electrónico es *spam* o no) y modelos de regresión (como predecir el precio de una casa en función de sus características).

En el **aprendizaje no supervisado**, los datos de entrenamiento no están etiquetados. El modelo debe encontrar patrones, estructuras o agrupamientos inherentes en los datos sin conocer las respuestas correctas de antemano. El aprendizaje no supervisado se utiliza para técnicas descriptivas que ayudan a entender mejor la estructura y las relaciones en los datos. Esto incluye el *clustering* (para agrupar datos similares) y la reducción de dimensionalidad (para representar datos en un espacio de menor dimensión).

Ambos enfoques, supervisado y no supervisado, son fundamentales en la ciencia de datos y el aprendizaje automático, y se utilizan en una variedad de aplicaciones según los objetivos de modelado y los datos disponibles.

Técnicas de análisis de datos masivos

Técnicas predictivas:

- **Clasificación:** el atributo a predecir *(target)* es de tipo cualitativo (categoría). Ej. clasificación de objetos en imágenes: perro, gato, avión, *laptop*. Algoritmos: RNA (MLP), SVM, decision tree, K-NN, Naive Bayes, logistic regression, Random Forest (ensemble).

- **Regresión:** similar a la clasificación, pero el atributo a predecir es de tipo cuantitativo. Algoritmos: linear and multiple regression with least-squares method, RNA, Regression tree, SVM, Random Forest.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Técnicas Descriptivas:

- **Agrupamiento:** segmentación en grupos homogéneos. Ej. clientes A, B, C. Algoritmos: k-means, Expectation Maximization (EM), K-NN.

- **Asociación:** identificación de productos que habitualmente se compran juntos (análisis de la canasta). Ej. pan, azúcar -> leche. Reglas antecedente-consecuente. Algoritmos: A priori, FP Growth.

En la Figura 11 se muestra los tipos de modelos de machine learning existentes en la literatura.

Figura 11. Tipos de modelos de machine learning

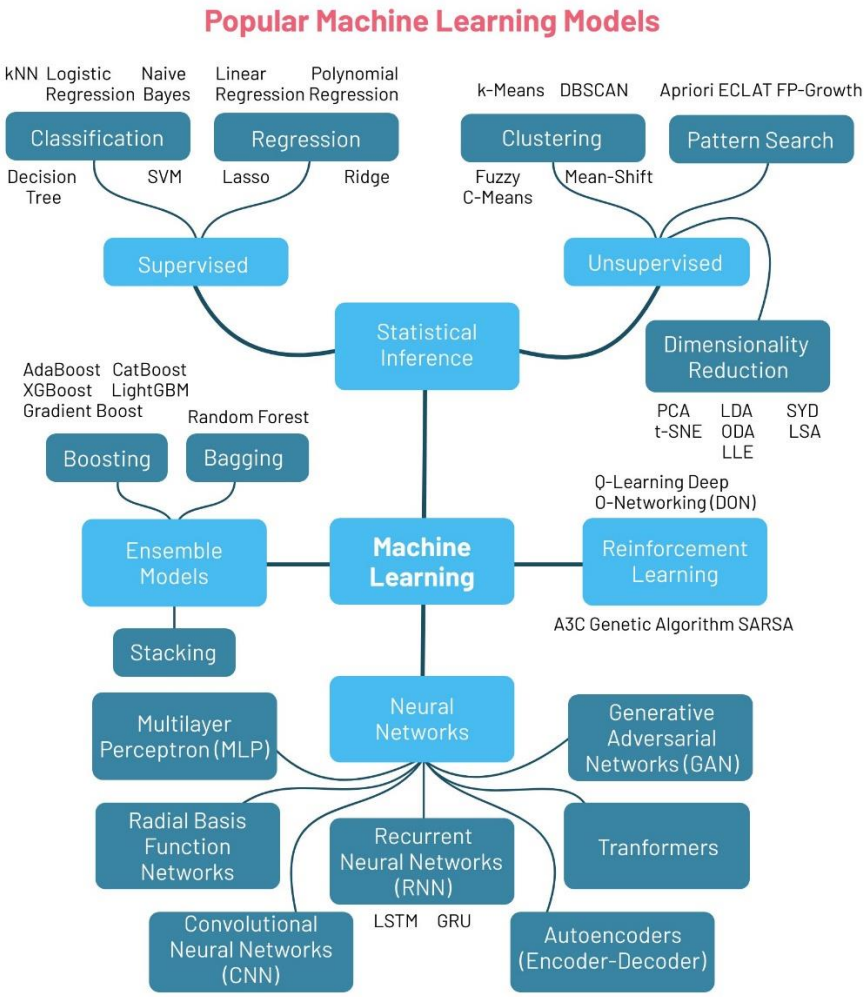

Fuente: ML4Devs (2020)

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

En lo que sigue de la unidad se revisarán ciertos algoritmos predictivos de clasificación.

2.2. Configuración del entorno de Python, Keras y TensorFlow

Siga el tutorial disponible aquí, para configurar localmente un entorno de desarrollo de aprendizaje automático utilizando la herramienta **Anaconda Navigator**. Anaconda es una distribución libre y abierta de los lenguajes Python y R, utilizada en ciencia de datos, y aprendizaje automático que permite instalar y administrar paquetes, dependencias y entornos para las ciencias de datos con Python de una manera muy sencilla. Ayuda a desarrollar proyectos de ciencia de datos utilizando diversos entornos de desarrollo como Jupyter, PyCharm, Spyder, VS Code, Orange, RStudio, etc., como se illustran en la Figura 12.

En este tutorial se cubrirá los siguientes pasos:

- Descargar Anaconda navigator
- Instalar Anaconda
- Iniciar y actualizar Anaconda
- Actualizar la biblioteca scikit-learn
- Instalar bibliotecas de aprendizaje profundo

Figura 12. Entornos de desarrollo disponibles en Anaconda Navigator

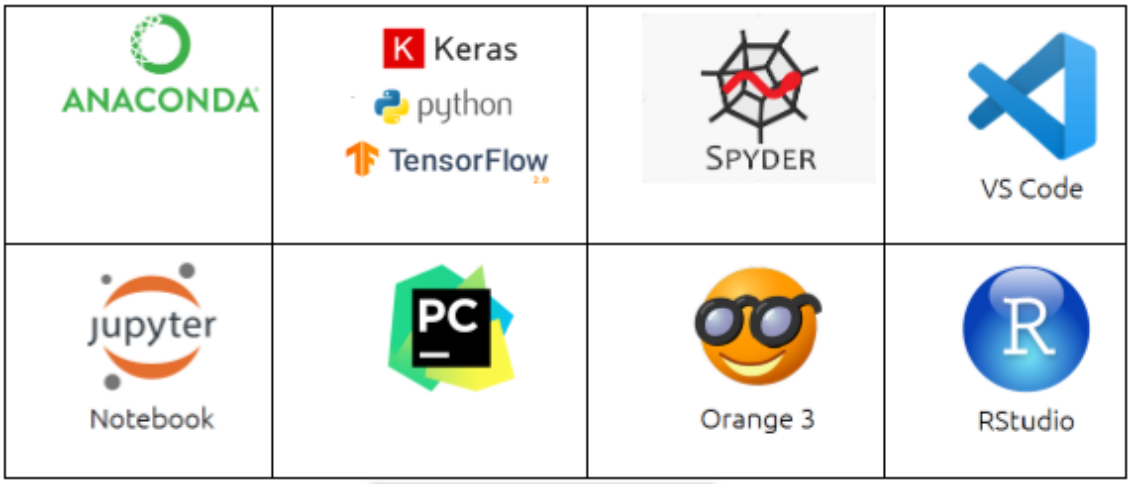

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

2.3. Uso de la GPU en TensorFlow

Siga el tutorial disponible aquí, para configurar localmente la GPU y sacar provecho del *hardware* disponible en su PC/laptop para el entrenamiento de modelos de datos.

En este tutorial se cubrirá los siguientes pasos:

- Configuración
- Descripción general
- Ubicación del dispositivo de registro
- Colocación manual de dispositivos
- Limitar el crecimiento de la memoria de la GPU
- Uso de una sola GPU en un sistema multi-GPU
- Uso de varias GPU

2.4. Google Colaboratory

Otra alternativa es el uso de un entorno de desarrollo gratuito en la nube como Google Colaboratory, o "Colab", que permite a cualquier usuario escribir y ejecutar código arbitrario de Python en el navegador. Es especialmente adecuado para tareas de aprendizaje automático, análisis de datos y educación.

Algunas de las principales características de Colab son:

- Dado que se ejecuta en una máquina de Google, no es necesario realizar ninguna configuración.
- Google proporciona acceso gratuito a las GPU (limitadas).
- Es fácil de compartir, como cualquier archivo en el Google Drive.

Lo primero que se debe hacer para utilizar el Google Colab es acceder a la siguiente dirección URL en donde se da la bienvenida a Colab e indica los primeros pasos y algunos recursos disponibles, como se indica la Figura 13.

https://colab.research.google.com/notebooks/intro.ipynb

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Figura 13. Google Colab

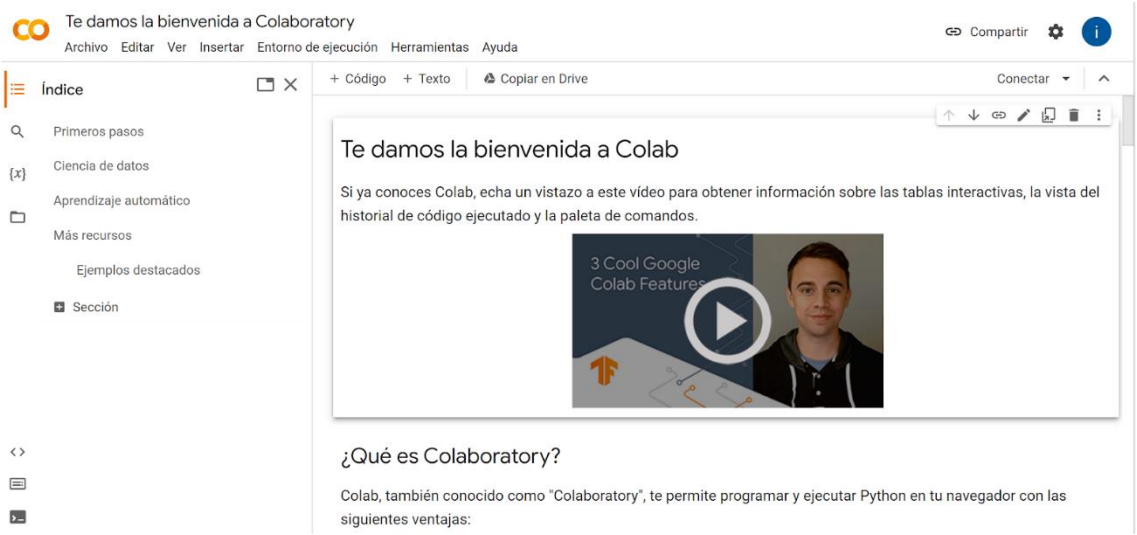

En este punto siéntase libre de explorar el entorno de Colab teniendo una conexión a Internet.

Trabajo autónomo:

Cree y ejecute un script básico de Python (creado anteriormente) en Colab y Spyder/VS Code/Jupyter Notebook.

2.5. Conjuntos de datos disponibles para ciencia de datos

Existe una gran variedad de datasets públicamente disponibles para realizar tareas de análisis de datos. Algunos de ellos son los siguientes:

- UCI repo (https://archive.ics.uci.edu/)
- Kaggle (https://www.kaggle.com/datasets)
- Google dataset search (https://datasetsearch.research.google.com/)
- sklearn.datasets (https://scikit-learn.org/stable/datasets/toy_dataset.html)
- https://www.datosabiertos.gob.ec/
- https://datos.gob.es/es/
- etc.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Tamaños de datasets:

- **Dataset pequeño:** conjunto de datos del orden de un millar (alrededor de mil) de ejemplos de entrenamiento.

- **Dataset mediano:** conjunto de datos del orden de decenas de miles de ejemplos de entrenamiento.

- **Dataset grande:** conjunto de datos del orden de centenas de miles o millones de ejemplos de entrenamiento.

2.6. Algoritmos predictivos de clasificación

2.6.1. Regresión logística

Es un método de aprendizaje automático supervisado utilizado para resolver problemas de clasificación binaria o multinomial (más de dos clases). Aunque su nombre incluye la palabra "regresión", en realidad se trata de un algoritmo de clasificación.

Se utiliza comúnmente en una variedad de aplicaciones, como la detección de *spam* de correo electrónico, diagnósticos médicos, clasificación de documentos, entre otros. Por ejemplo, en medicina, es fundamental para predecir la probabilidad de ocurrencia de ciertas enfermedades, como la diabetes o el cáncer, basándose en factores de riesgo. En el sector financiero, se aplica en la evaluación del riesgo crediticio, determinando la probabilidad de que un cliente incumpla con sus pagos. En *marketing*, se utiliza para predecir la probabilidad de que un cliente compre un producto o responda a una campaña específica.

Además, la regresión logística es esencial en el campo de la investigación social y política para analizar la influencia de diversas variables sobre resultados binarios, como la decisión de votar por un candidato.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Su capacidad para proporcionar probabilidades y su facilidad de interpretación la hacen una herramienta valiosa para la toma de decisiones basada en datos.

En la Figura 14 se indican algunos pros y contras del algoritmo de regresión logística.

Figura 14. Pros y contras del algoritmo de regresión logística

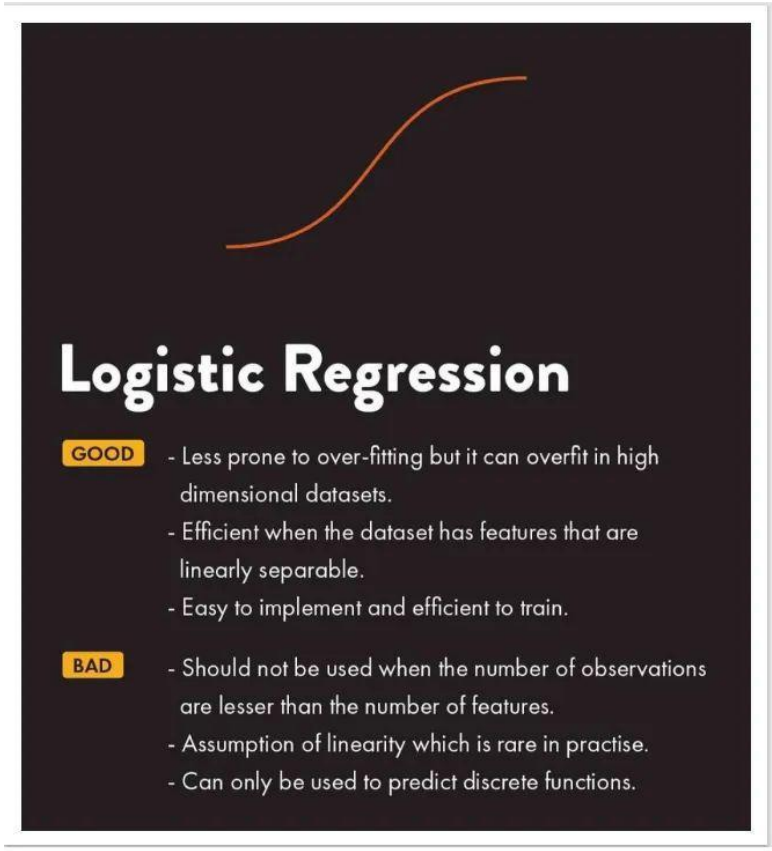

Fuente: ML4Devs (2020)

2.6.2. Vecinos más cercanos (K-NN)

El algoritmo k-Nearest Neighbors (k-NN) es un método de aprendizaje automático supervisado utilizado para problemas de clasificación y regresión. El algoritmo k-NN (k-nearest neighbors) tiene diversas aplicaciones prácticas en campos como el análisis de datos, aprendizaje automático y sistemas de recomendación. En medicina, se utiliza para

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

clasificar pacientes en categorías de riesgo basándose en características similares a casos conocidos. En el sector financiero, ayuda en la detección de fraudes identificando patrones de transacciones sospechosas similares a casos previos de fraude. En el comercio minorista y en servicios de *streaming*, k-NN es esencial para los sistemas de recomendación, sugiriendo productos, películas o música basándose en las preferencias de usuarios con gustos similares. También es utilizado en la agricultura para la clasificación y diagnóstico de enfermedades de plantas, y en la robótica para la navegación y clasificación de obstáculos.

La simplicidad y efectividad del algoritmo lo hacen versátil para aplicaciones que requieren clasificación o recomendación basada en similitudes de datos.

En la Figura 15 indican algunos pros y contras del algoritmo K-NN.

Figura 15. Pros y contras del algoritmo K-NN

Fuente: ML4Devs (2020)

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Conclusiones

En esta unidad se ha revisado las herramientas (Colab, Spyder, VS Code, Jupyter notebook, etc.) y conjuntos de datos (UCI Repo, Kaggle, sklearn.datasets, etc.) para ciencia de datos, así como dos algoritmos predictivos de clasificación, regresión logística y vecinos más cercanos (K-NN). Los algoritmos de clasificación tienen un sin número de aplicaciones prácticas en diversos campos. En el sector financiero, se utilizan para evaluar la solvencia crediticia de los clientes, mientras que, en el ámbito de la salud, ayudan a diagnosticar enfermedades y a predecir resultados de tratamientos médicos. En el comercio electrónico, facilitan la recomendación personalizada de productos a partir del comportamiento de compra de los usuarios. Además, en la seguridad informática, contribuyen a la detección de actividades fraudulentas y en el mantenimiento predictivo, permiten prever fallos en equipos industriales, optimizando así las operaciones y reduciendo los costes. Estos algoritmos son valiosos por su capacidad de interpretar grandes volúmenes de datos y tomar decisiones informadas, lo que los hace esenciales en la era del Big Data. Sin embargo, para obtener un mejor rendimiento de cada uno de ellos es importante experimentar con los parámetros de cada algoritmo. Además, hay que considerar las ventajas y desventajas que presentan cada uno para la selección adecuada de un algoritmo de clasificación.

Bibliografía:

Berzal, Fernando (2019). *Redes neuronales & Deep Learning*. USA: Independently published.

Brownlee, J. (2023). *Machine Learning Mastery*.
https://machinelearningmastery.com/

García-Santillán, I. (2023). *Ciencia y analítica de datos*. Maestría en Inteligencia Artificial aplicada. Universidad Hemisferios.

InstitutoEmprende (2023). *Cómo crear un árbol de decisión*.
https://institutoemprende.com/como-crear-un-arbol-de-decisiones/

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.

Lara, J. (2014). *Minería de Datos.* Madrid: CEF-Udima

MathWorks (2023). *Machine Learning in Matlab.*
https://la.mathworks.com/help/stats/machine-learning-in-matlab.html

MaximaFormacion (2023). *Qué son los árboles de decisión y para qué sirven.* https://www.maximaformacion.es/blog-dat/que-son-los-arboles-de-decision-y-para-que-sirven/

ML4Devs (2020). *An Engineer's Trek into Machine Learning.*
https://www.ml4devs.com/articles/machine-learning-intro-for-developers/

Sierra, B. (2006). *Aprendizaje automático: conceptos básicos y avanzados.* Madrid: Prentice-Hall.

Torres, J. (2020). *Python Deep Learning: Introducción práctica con Keras y TensorFlow 2*. Marcombo.

UAB. (2016). *Curso de Detección de objetos.* Universidad Autónoma de Barcelona.

Todos los derechos reservados. Prohibida la reproducción total o parcial del documento y su distribución por cualquier medio impreso o electrónico sin la autorización escrita de EIG Campus.